



การออกแบบและการพัฒนาค้างข้อมูลของชุดข้อมูล
อาชญากรรมเชิงพื้นที่และเวลาในเมืองชิคาโก
Design and Development of a Data Warehouse
for the Chicago Spatial-Temporal Crime Dataset

จัดทำโดย

1. นายจิรายุ	ธิพันธ์	67070022
2. นายธนชิน	ชูเกียรติชัย	67070063
3. นายพาทิศ	เกษมมงคลชัย	67070113
4. นายพิชญุต	ยันต์โกเศศ	67070116
5. นายภณพิชิต	จิรังกุล	67070125
6. นายสุภรินทร์	นำศรีเจริญสุข	67070308

เสนอ

อาจารย์ประจำวิชา

อ. เณลิมพล ศิริกายน

รายงานนี้เป็นส่วนหนึ่งของรายวิชาการสร้างคลังข้อมูล (DATA WAREHOUSING)

รหัสวิชา 06026212 ภาคเรียนที่ 1 ปีการศึกษา 2569

หลักสูตรวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

COPYRIGHT 2026

FACULTY OF INFORMATION TECHNOLOGY

KING MONGKUT'S INSTITUTE OF TECHNOLOGY LADKRABANG

ใบรับรองโครงการ (PROJECT)

เรื่อง

การออกแบบและการพัฒนาค้างข้อมูลของชุดข้อมูล
อาชญากรรมเชิงพื้นที่และเวลาในเมืองชิคาโก
Design and Development of a Data Warehouse
for the Chicago Spatial-Temporal Crime Dataset

นายภณพิชิต จิรังกุล 67070125

ขอรับรองว่ารายงานฉบับนี้ ข้าพเจ้าไม่ได้คัดลอกมาจากที่ใด
รายงานฉบับนี้ได้รับการตรวจสอบและอนุมัติให้เป็นส่วนหนึ่งของ
การศึกษาวិชาการสร้างคลังข้อมูล
คณะเทคโนโลยีสารสนเทศ
ภาคเรียนที่ 1 ปีการศึกษา 2569

.....ภณพิชิต จิรังกุล.....

(นาย/นางสาว.....ภณพิชิต จิรังกุล.....)

หัวข้อโครงการ	การออกแบบและการพัฒนาค้างข้อมูลของชุดข้อมูล		
	อาชญากรรมเชิงพื้นที่และเวลาในเมืองชิคาโก		
นักศึกษา	นายจิรายุ	ธิพันธ์	67070022
	นายธนชิน	ชูเกียรติชัย	67070063
	นายพาติศ	เกษมมงคลชัย	67070113
	นายพิชญุต	ยันต์โกเศศ	67070116
	นายภณพิชิต	จิรังกุล	67070125
	นายสุภรินทร์	นำศรีเจริญสุข	67070308
แขนงวิชา	วิศวกรรมข้อมูล (Data Engineering)		
ปีการศึกษา	1/2569		

บทคัดย่อ

การรับมืออาชญากรรมในเมืองชิคาโกยังขาดประสิทธิภาพเชิงรุก เนื่องจากระบบฐานข้อมูลเดิมออกแบบมาเพื่อบันทึกคดีรายวันเท่านั้น ข้อมูลสถิติและเขตพื้นที่ที่ตรวจจึงกระจุกกระจาย ไม่เอื้อต่อการประมวลผลข้อมูลย้อนหลังขนาดใหญ่ ทำให้การวิเคราะห์แนวโน้มมีความล่าช้า

คณะผู้จัดทำจึงออกแบบและพัฒนาระบบคลังข้อมูล (Data Warehouse) เพื่อรวบรวม บำรุงการ และ จัดโครงสร้างข้อมูลอาชญากรรมให้พร้อมสำหรับการวิเคราะห์เชิงทำนายและการแสดงผลเชิงภาพ สะท้อนความหนาแน่นและความเสี่ยงเชิงพื้นที่และเวลาได้อย่างเป็นเอกภาพ

ระบบนี้จะช่วยเปลี่ยนผ่านการทำงานสู่การเฝ้าระวังเชิงรุก สนับสนุนการจัดสรรกำลังพลสายตรวจได้ตรงจุด และช่วยให้ผู้บริหารตัดสินใจเชิงนโยบายความปลอดภัยสาธารณะบนพื้นฐานของข้อมูลได้อย่างแม่นยำ

Project Title Design and Development of a Data Warehouse
for the Chicago Spatial-Temporal Crime Dataset

Abstract

Crime response in the City of Chicago remains predominantly reactive, largely because existing databases were designed primarily for day-to-day incident logging. Consequently, crime records and patrol boundary data remain fragmented and ill-suited for large-scale historical processing, leading to significant delays in trend analysis.

To address these limitations, the project team designed and developed a Data Warehouse system to consolidate, integrate, and structure large-scale crime data for predictive analytics and visual reporting, effectively capturing spatial-temporal crime density and risk patterns across the city.

This system facilitates a strategic shift toward proactive surveillance, enabling targeted patrol resource allocation and empowering leadership to make precise, data-driven public safety policy decisions.

กิตติกรรมประกาศ

โครงการเรื่อง การออกแบบและการพัฒนาลังข้อมูลของชุดข้อมูลอาชญากรรมเชิงพื้นที่และเวลาในเมืองชิคาโก สำเร็จลุล่วงไปได้ด้วยความอนุเคราะห์และความช่วยเหลือจากหลายบุคคล ผู้จัดทำขอขอบพระคุณเป็นอย่างสูงมายังทุกท่าน ดังต่อไปนี้

ขอขอบพระคุณ อ. เฉลิมพล ศิริกายน อาจารย์ที่ปรึกษารายวิชา ที่ได้ให้คำแนะนำ ข้อคิดเห็น รวมถึงตรวจสอบและแก้ไขข้อบกพร่องต่าง ๆ ตลอดระยะเวลาการดำเนินงานจนกระทั่งโครงการนี้เสร็จสมบูรณ์

ขอขอบคุณเพื่อน ๆ ทุกคนที่ให้คำแนะนำ ความช่วยเหลือ และคำปรึกษาในด้านต่าง ๆ ได้ให้กำลังใจและสนับสนุนในทุกด้านมาโดยตลอด

ผู้จัดทำหวังว่าโครงการฉบับนี้จะเป็นประโยชน์

คณะผู้จัดทำ

สารบัญ

หน้า

สารบัญ |

Gtest..... 1

สารบัญรูป

หน้า

สารบัญ	14
สารบัญ.....	14
สารบัญ	14
สารบัญ	50
สารบัญ	14
สารบัญ	14
สารบัญ	14
สารบัญ	14

สารบัญตาราง

หน้า

สารบัญ	14
สารบัญ	14
สารบัญ	14
สารบัญ	50
สารบัญ	14
สารบัญ	14
สารบัญ	14
สารบัญ	14

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

อาชญากรรมในเขตเมืองมีแนวโน้มเพิ่มขึ้นตามการขยายตัวของประชากรและการเติบโตทางเศรษฐกิจ ขณะที่รูปแบบการปฏิบัติงานของหน่วยงานบังคับใช้กฎหมายในปัจจุบันยังคงเน้นการดำเนินงานเชิงรับ คือการเข้าตรวจสอบและสืบสวนหลังเกิดเหตุการณ์ขึ้นแล้ว ส่งผลให้ไม่สามารถยับยั้งความเสียหายต่อชีวิตและทรัพย์สินของประชาชนได้ล่วงหน้า

ปัญหาดังกล่าวมีสาเหตุหลักมาจากการขาดโครงสร้างพื้นฐานด้านข้อมูลที่พร้อมสำหรับการวิเคราะห์เชิงลึก โดยสามารถสะท้อนผ่านข้อจำกัดในทางปฏิบัติดังต่อไปนี้:

1. ระบบจัดเก็บข้อมูลเดิมถูกออกแบบมาเพื่อรองรับเพียงธุรกรรมการบันทึกคดีประจำวัน จึงไม่เอื้อต่อการประมวลผลข้อมูลสถิติย้อนหลังสะสมนับล้านรายการ เมื่อต้องสรุปแนวโน้มหรือเปรียบเทียบสถิติระยะยาว จะเกิดปัญหาความล่าช้าอย่างรุนแรง และอาจส่งผลกระทบต่อความเสถียรของระบบงานหน่วยงาน
2. ชุดข้อมูลที่จำเป็นต้องใช้งานถูกแยกออกเป็นหลายส่วนและจัดเก็บในรูปแบบไฟล์ CSV ที่กระจัดกระจาย เช่น ข้อมูลรายงานการเกิดเหตุ ข้อมูลขอบเขตทางภูมิศาสตร์ ซึ่งไฟล์เหล่านี้มีการอัปเดตข้อมูลใหม่เป็นประจำทุกวัน ทำให้ผู้ปฏิบัติงานต้องแบกรับภาระในการดาวน์โหลด รวมไฟล์ และเชื่อมโยงข้อมูลขนาดใหญ่ด้วยตนเองซ้ำๆ ทุกวัน
3. ข้อมูลคดีในอดีตมีการอัปเดตสถานะย้อนหลังตามผลการสืบสวน เช่น การจับกุมคนร้ายได้ในภายหลัง พร้อมมีคอลัมน์ประทับเวลาการแก้ไขกำกับไว้ หากไม่มีระบบคลังข้อมูลมาช่วยจัดการ การนำไฟล์มาประมวลผลใหม่อาจทำให้เกิดข้อมูลซ้ำซ้อนหรือได้สถิติในอดีตที่ไม่เป็นปัจจุบัน
4. การคำนวณตัวชี้วัดสำคัญ เช่น อัตราความสำเร็จในการจับกุมหรือดัชนีความเสี่ยง ยังขาดสูตรและนิยามที่เป็นมาตรฐานกลางร่วมกัน ทำให้เมื่อแต่ละหน่วยงานนำไฟล์ CSV ไปติดต่อและประมวลผลเอง จึงได้ผลลัพธ์ที่ไม่สอดคล้องกันและยากต่อการนำไปใช้กำหนดนโยบายความปลอดภัยสาธารณะอย่างเป็นรูปธรรม

1.2 วัตถุประสงค์

1. เพื่อออกแบบและพัฒนาระบบคลังข้อมูล สำหรับรวบรวม บูรณาการ และจัดเก็บข้อมูลสถิติอาชญากรรมเชิงพื้นที่และเวลาขนาดใหญ่ให้เป็นมาตรฐานกลางเดียวกัน
2. เพื่อพัฒนาระบบการจัดการและปรับปรุงข้อมูลอัตโนมัติ ที่รองรับการอัปเดตข้อมูลใหม่รายวันและการแก้ไขสถานะคดีย้อนหลังได้อย่างถูกต้อง โดยไม่เกิดข้อมูลซ้ำซ้อน
3. เพื่อพัฒนาระบบสารสนเทศเชิงภาพ ในการวิเคราะห์แนวโน้มและสะท้อนความเสี่ยงเชิงพื้นที่ สำหรับสนับสนุนการวางแผนจัดสรรกำลังพลและการตัดสินใจเชิงรุกของผู้ใช้งาน

1.3 ขอบเขตของโครงการ

1.3.1 ขอบเขตด้านข้อมูล

- ใช้ชุดข้อมูลสถิติอาชญากรรมเมืองชิคาโก (Crimes - 2001 to Present) ย้อนหลังตั้งแต่ปี 2001 จนถึงปัจจุบัน
- ใช้ชุดข้อมูลเสริม (Lookup Datasets) ได้แก่ ตารางรหัสประเภทคดี (IUCR Codes) และข้อมูลขอบเขตเชิงพื้นที่ (Beat, District, Ward, Community Area)
- ข้อมูลที่นำมาประมวลผลเป็นข้อมูลทฤษฎีที่เปิดเผยต่อสาธารณะ ไม่ครอบคลุมข้อมูลส่วนบุคคลของผู้เสียหายหรือผู้ต้องหา (No PII Data)

1.3.2 ขอบเขตด้านการพัฒนาระบบคลังข้อมูล

- ออกแบบแบบจำลองข้อมูลแบบหลายมิติโดยใช้โครงสร้างแบบ **Star Schema**
- พัฒนาระบบการรวบรวมและแปลงข้อมูลเพื่อรองรับการนำเข้าข้อมูลสะสมในอดีต (Initial Load) และการปรับปรุงข้อมูลใหม่รายวัน (Daily Incremental Refresh)
- จัดการการเปลี่ยนแปลงของข้อมูลตามกาลเวลาด้วยเทคนิค Slowly Changing Dimensions

1.3.3 ขอบเขตด้านการแสดงผลและผู้ใช้งาน

- พัฒนาระบบแสดงผลสารสนเทศเชิงภาพ (Dashboard) ในรูปแบบแผนที่ความหนาแน่นเชิงพื้นที่ (Heatmap) และกราฟวิเคราะห์แนวโน้มตามช่วงเวลา
- มุ่งเน้นการสนับสนุนการตัดสินใจสำหรับ 2 กลุ่มผู้ใช้งานหลัก ได้แก่ ผู้บริหารระดับนโยบาย และฝ่ายวางแผนกำลังพลสายตรวจ

1.3.4 สิ่งที่อยู่นอกเหนือขอบเขต (Out-of-Scope)

- ไม่ครอบคลุมการประมวลผลแบบทันทีทันใดในระดับวินาที (Real-time Streaming Analytics)
- ไม่ครอบคลุมการส่งการตำรวจหรือการรับแจ้งเหตุฉุกเฉินอัตโนมัติ (Automated 911 Dispatch)

1.4 ประโยชน์ที่คาดว่าจะได้รับ (Expected Benefits)

1.4.1 ประโยชน์เชิงรูปธรรม (Tangible Benefits):

- ลดระยะเวลาในการดึงข้อมูลและประมวลผลสถิติอาชญากรรมย้อนหลังจากเดิมที่ใช้เวลานาน ให้สามารถตอบสนองบนแดชบอร์ดได้ภายใน 3-5 วินาที
- มีระบบท่อข้อมูลอัตโนมัติที่ช่วยลดภาระงานและเวลาของเจ้าหน้าที่ในการดาวน์โหลด รวมไฟล์ CSV และทำความสะอาดข้อมูลซ้ำๆ ทุกวัน
- ได้ระบบคลังข้อมูลที่มีความถูกต้องของตัวชี้วัด โดยมีกระบวนการตรวจสอบคุณภาพข้อมูล (Data Quality Gate) ป้องกันข้อมูลซ้ำซ้อน 100%

1.4.2 ประโยชน์เชิงนามธรรม (Intangible Benefits):

- ช่วยเปลี่ยนผ่านรูปแบบการทำงานของหน่วยงานจากการตั้งรับ (Reactive) ไปสู่การเฝ้าระวังเชิงรุก (Proactive Surveillance)
- ผู้บริหารและฝ่ายปฏิบัติการมีฐานข้อมูลที่เป็นมาตรฐานกลางแหล่งเดียวกัน (Single Source of Truth) ช่วยลดความสับสนของตัวเลขสถิติ
- สนับสนุนการจัดสรรทรัพยากรและสายตรวจได้อย่างมีประสิทธิภาพและตรงจุดบนพื้นฐานของข้อมูลจริง (Data-Driven Decision Making)

1.5 ข้อจำกัดของโครงการ (Project Limitations)

1. ข้อมูลพิกัดสถานที่เกิดเหตุ (Latitude, Longitude และ Address) ในระบบต้นทางอยู่ในระดับช่วงถนน เพื่อความปลอดภัยและสิทธิความเป็นส่วนตัวของผู้เสียหาย จึงไม่สามารถระบุตำแหน่งบ้านเลขที่จริงได้
2. ข้อมูลสถานะการจับกุมในคดีล่าสุดอาจมีความล่าช้าในการอัปเดตจากระบบต้นทางตามกระบวนการทางคดีความของเจ้าหน้าที่ตำรวจ

3. โครงการนี้พัฒนาขึ้นเพื่อวัตถุประสงค์ทางการศึกษาและสาธิตแนวคิด (Proof of Concept) ไม่ได้เชื่อมต่อกับฐานข้อมูลความลับภายในของสำนักงานตำรวจ

1.6 นิยามศัพท์เฉพาะ (Definition of Terms)

- **CLEAR (Citizen Law Enforcement Analysis and Reporting):** ระบบฐานข้อมูลสารสนเทศหลักในการรับแจ้งและบันทึกคดีของกรมตำรวจชิคาโก
- **IUCR (Illinois Uniform Crime Reporting):** ระบบรหัส 4 หลักมาตรฐานที่ใช้จำแนกประเภทและลักษณะความผิดของคดีอาชญากรรมในรัฐอิลลินอยส์
- **Beat:** เขตพื้นที่ที่ตรวจย่อยที่เล็กที่สุดของตำรวจชิคาโก โดยแต่ละ Beat จะมีรหัสสายตรวจประจำการเฉพาะ
- **Star Schema:** รูปแบบการจำลองข้อมูลที่ประกอบด้วยตารางข้อเท็จจริง (Fact Table) อยู่ตรงกลางและล้อมรอบด้วยตารางมิติ (Dimension Tables)
- **SCD (Slowly Changing Dimensions):** เทคนิคในคลังข้อมูลที่ใช้จัดการและเก็บประวัติการเปลี่ยนแปลงของมิติข้อมูลตามช่วงเวลา

บทที่ 2

ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

2.1 แนวคิดพื้นฐานและสถาปัตยกรรมคลังข้อมูล

คลังข้อมูล (Data Warehouse) คือระบบฐานข้อมูลที่ได้รับการออกแบบและสร้างขึ้นมาโดยเฉพาะเพื่อสนับสนุนการวิเคราะห์ข้อมูลและการตัดสินใจเชิงกลยุทธ์ของผู้บริหารและนักวิเคราะห์ในองค์กร โดยการรวบรวมข้อมูลจากระบบปฏิบัติการที่หลากหลาย นำมาจัดโครงสร้างใหม่ให้อยู่ในรูปแบบที่เอื้อต่อการสืบค้นและประมวลผลย้อนหลัง แทนการเน้นการบันทึกธุรกรรมประจำวัน

2.1.1 นิยามและคุณสมบัติ 4 ประการของคลังข้อมูล (W.H. Inmon)

William H. Inmon ซึ่งได้รับการยอมรับว่าเป็นบิดาแห่งคลังข้อมูล ได้ให้นิยามว่า คลังข้อมูลที่ดีจะต้องประกอบด้วยคุณสมบัติพื้นฐาน 4 ประการ ซึ่งเมื่อนำมาประยุกต์ใช้กับระบบข้อมูลอาชญากรรม จะมีลักษณะดังนี้:

1. **Subject-Oriented:** คลังข้อมูลจะจัดเก็บข้อมูลโดยจำแนกตามหัวข้อหลักทางธุรกิจ (Business Subjects) เพื่อตอบคำถามเชิงวิเคราะห์ แทนที่จะจัดเก็บตามโมดูลการทำงานของโปรแกรมซอฟต์แวร์
2. **Integrated:** ข้อมูลที่ไหลเข้าสู่คลังข้อมูลมักมาจากระบบต้นทางที่หลากหลาย ซึ่งอาจมีรูปแบบข้อมูล นิยาม หรือรหัสที่แตกต่างกัน คลังข้อมูลจะต้องมีกระบวนการแปลงและปรับมาตรฐานข้อมูลให้เป็นรูปแบบเดียวกันทั้งระบบ
3. **Non-Volatile:** เมื่อข้อมูลถูกประมวลผลและไหลเข้าสู่คลังข้อมูลแล้ว ข้อมูลเหล่านั้นจะกลายเป็นข้อมูลสำหรับอ่านเพียงอย่างเดียว (Read-only) จะไม่มีการแก้ไขทับหรือลบข้อมูลในอดีตทิ้งเหมือนในฐานข้อมูลงานประจำวัน การเปลี่ยนแปลงใดๆ จะถูกบันทึกเป็นการเพิ่มแถวข้อมูลใหม่เข้าไปเพื่อเก็บประวัติศาสตร์
4. **Time-Variant:** คลังข้อมูลจะเก็บสะสมข้อมูลย้อนหลังในระยะยาว (เช่น 5–20 ปีขึ้นไป) และทุกระเบียนข้อมูลจะต้องมีมิติเวลา (Time Dimension หรือ Timestamp) กำกับอยู่เสมอ เพื่อให้สามารถนำมาเปรียบเทียบแนวโน้มและวิเคราะห์ความเปลี่ยนแปลงตามช่วงเวลาได้

2.1.2 การเปรียบเทียบระบบ OLTP กับ OLAP

ระบบฐานข้อมูลสารสนเทศแบ่งออกเป็น 2 ประเภทหลักตามลักษณะการใช้งาน ได้แก่ ระบบประมวลผลธุรกรรมออนไลน์ (Online Transaction Processing: OLTP) และระบบประมวลผลเชิงวิเคราะห์ออนไลน์ (Online Analytical Processing: OLAP)

ในการพัฒนาระบบข้อมูลอาชญากรรม ความแตกต่างระหว่างระบบ **CLEAR (OLTP)** ของกรมตำรวจชिकाโก กับ **Crime Data Warehouse (OLAP)** สรุปได้ดังตารางเปรียบเทียบต่อไปนี้:

มิติการเปรียบเทียบ	ระบบ OLTP (เช่น ระบบ CLEAR เดิม)	ระบบ OLAP (ระบบ Crime Data Warehouse)
วัตถุประสงค์หลัก	บันทึกธุรกรรมการเกิดเหตุและจับกุม รายงานแบบเรียลไทม์	วิเคราะห์แนวโน้ม สถิติย้อนหลัง และสนับสนุนการตัดสินใจเชิงนโยบาย
ลักษณะการเข้าถึงข้อมูล	อ่านและเขียนทีละระเบียนอย่างรวดเร็ว	อ่านข้อมูลพร้อมกันจำนวนมากโดยไม่มีการ Update แบบแถวเดี่ยว
โครงสร้างฐานข้อมูล	Normalized (3NF): แดกตารางย่อยเพื่อลดความซ้ำซ้อนของข้อมูล	Denormalized (Star Schema): ลดความซับซ้อนของการ Join เพื่อเน้นความเร็วในการอ่าน
การจัดเก็บข้อมูลกายภาพ	บันทึกข้อมูลเรียงเป็นแถว เหมาะกับการเรียกดูข้อมูลทั้งคดี	จัดเก็บแยกตามคอลัมน์ สแกนเฉพาะคอลัมน์ที่ต้องใช้คำนวณได้อย่างรวดเร็ว
รูปแบบคำสั่ง (Query)	คำสั่ง SQL สั้น ค้นหาเฉพาะเจาะจง	คำสั่งซับซ้อน เช่น การสรุปผลรวม SUM(), COUNT(), GROUP BY ข้ามหลายล้านแถว
การใช้ทรัพยากร	เน้นความเร็วในการตอบสนองคำสั่งต่อวินาที	เน้นพลังการประมวลผลหน่วยความจำและดิสก์เพื่อกวาดข้อมูลขนาดใหญ่

2.1.3 การเปรียบเทียบแนวคิดสถาปัตยกรรม: Kimball (Bottom-up) กับ Inmon (Top-down)

ในการออกแบบสถาปัตยกรรมคลังข้อมูล มีแนวคิดหลักที่เป็นที่ยอมรับในระดับสากลอยู่ 2 แนวคิด ได้แก่:

- แนวคิดของ Bill Inmon (Top-down Approach): มุ่งเน้นการสร้าง **คลังข้อมูลระดับองค์กร** เป็นศูนย์กลางก่อน โดยจัดโครงสร้างข้อมูลแบบแตกกระจายลดความซ้ำซ้อนเพื่อให้เกิดความแม่นยำสูงสุด และหลีกเลี่ยงข้อมูลซ้ำซ้อน จากนั้นจึงค่อยแยกข้อมูลเฉพาะด้านออกมาเป็น **Data Mart** ให้แต่ละแผนก

ใช้งาน แนวทางนี้มีความถูกต้องสูง มั่นคง แต่ใช้เวลาและงบประมาณในการพัฒนานานมาก ไม่ยืดหยุ่นต่อการเปลี่ยนแปลง

2. แนวคิดของ Ralph Kimball (Bottom-up Approach): มุ่งเน้นการตอบโจทย์กระบวนการทางธุรกิจเป็นสำคัญ โดยเริ่มต้นจากการสร้าง **Data Mart** ของแต่ละกระบวนการธุรกิจด้วยโครงสร้างแบบจำลองหลายมิติ (เช่น Star Schema) และเชื่อมโยง Data Mart แต่ละก้อนเข้าด้วยกันผ่าน **มิติข้อมูลที่ใช้ร่วมกัน (Conformed Dimensions)** ตามแนวคิด **Bus Architecture** ซึ่งทำให้ระบบมีความยืดหยุ่นสูง เริ่มต้นได้เร็ว และสามารถต่อยอดขยายระบบในอนาคตได้อย่างเป็นอิสระ

ประเด็นเปรียบเทียบ	แนวคิด Inmon (Top-down)	แนวคิด Kimball (Bottom-up)
จุดเริ่มต้นการพัฒนา	เริ่มจากสร้าง EDW รวมศูนย์ของทั้งองค์กรก่อน	เริ่มจากสร้าง Data Mart ตอบโจทย์กระบวนการธุรกิจทีละส่วน
โครงสร้างข้อมูลหลัก	Normalized (3NF) ตามหลักฐานข้อมูลเชิงสัมพันธ์	Dimensional Model (Star Schema / Snowflake Schema)
ความเร็วในการเห็นผล	ช้า ใช้เวลาวางแผนและสร้างโครงสร้างพื้นฐานยาวนาน	เร็ว (เห็นผลไว) สามารถส่งมอบให้ผู้ใช้งานเริ่มใช้งานได้ทันที
ความเป็นมิตรกับเครื่องมือ BI	ต่ำ ต้องแปลงข้อมูลเป็น Data Mart ก่อน จึงจะต่อ BI ได้ง่าย	สูงมาก ออกแบบให้เหมาะกับการ Slice/Dice และสร้างแดชบอร์ด
การเชื่อมโยงระบบ	รวมศูนย์อยู่ที่ฐานข้อมูล EDW เพียงแห่งเดียว	เชื่อมโยงข้ามกระบวนการผ่าน Conformed Dimensions
ความเหมาะสมกับองค์กร	เหมาะกับองค์กรขนาดใหญ่ที่มีกระบวนการซับซ้อนและงบประมาณสูงมาก	เหมาะกับทีมที่ต้องการความคล่องตัว (Agile), งานวิเคราะห์ข้อมูล, และโครงการที่เน้นผลสัมฤทธิ์

2.1.3 วงจรชีวิตการพัฒนาคลังข้อมูล (Data Warehouse Lifecycle)

การดำเนินงานในโครงการนี้ ยึดถือแนวทางตาม **Data Warehouse Project Lifecycle** จำนวน 7 ขั้นตอน เพื่อให้การพัฒนาระบบเป็นไปอย่างมีระบบ ไม่เกิดปัญหาการขยายขอบเขตงานเกิน และได้ผลลัพธ์ที่ตรงตามความต้องการของผู้ใช้งาน

1. **Requirement Specification:** ศึกษาบริบทองค์กรและรวบรวมความต้องการจากผู้มีส่วนได้ส่วนเสีย กำหนดคำถามทางธุรกิจที่ระบบต้องตอบ, กำหนดตัวชี้วัด (KPIs), กำหนดระดับความละเอียดของข้อมูล และจัดทำผังความสัมพันธ์ **Bus Matrix**
2. **Data Modeling:** นำ **Specification** ที่ได้มาแปลงเป็นโครงสร้างแบบจำลองข้อมูลเชิงตรรกะและเชิงกายภาพ โดยออกแบบตารางในรูปแบบ **Star Schema** จำแนกตารางข้อเท็จจริง และตารางมิติ, กำหนด **Surrogate Keys**, และวางกลยุทธ์การจัดการมิติข้อมูลที่มีการเปลี่ยนแปลงตามเวลา (SCD)
3. **ETL/ELT Design & Development:** สร้าง Data Pipeline เพื่อดึงข้อมูลเข้าสู่พื้นที่พักข้อมูลดิบ (Staging Layer) ดำเนินการทำความสะอาดข้อมูล (Data Cleansing) และแปลงให้อยู่ในโครงสร้าง **Star Schema** พร้อมวางระบบการโหลดข้อมูลรายวันแบบ **Incremental Refresh**
4. **Aggregation & OLAP Cubes:** สร้างตารางสรุปผลข้อมูลล่วงหน้า (Data Marts) เช่น ยอดรวมคดีรายวันแยกตามเขตตรวจ เพื่อเพิ่มความเร็วในการตอบสนองคำสั่ง query และออกแบบชั้นตัวชี้วัด (Metric Layer) เพื่อป้องกันข้อผิดพลาดทางสถิติ เช่น การหาค่าเฉลี่ยของค่าเฉลี่ย (Average of Averages)
5. **UI & Presentation Development:** พัฒนาระบบแสดงผลสารสนเทศ (Dashboard) เช่น แผนความร้อน (Heatmap) กราฟวิเคราะห์แนวโน้มตามช่วงเวลา โดยรองรับฟังก์ชันการเจาะลึกข้อมูล (Drill-down) และตัวกรอง (Filter) ข้อมูล
6. **Maintenance & Governance:** วางแผนการติดตามการเปลี่ยนแปลงของโครงสร้างข้อมูล, การตรวจสอบเส้นทางที่มาของข้อมูล (Data Lineage), และการกำหนดนโยบายการเก็บรักษาข้อมูล รวมถึงการเตรียมระบบให้พร้อมรองรับ Subject Area ใหม่ในอนาคต
7. **Testing & Deployment:** ดำเนินการทดสอบคุณภาพข้อมูล (Data Quality) ครอบคลุมทั้ง 6 มิติ (ความถูกต้อง, ความครบถ้วน, ความสอดคล้อง, ความถูกต้องตามเกณฑ์, ความไม่ซ้ำซ้อน, และความสดใหม่) พร้อมสร้างระบบกักกันข้อมูลที่ผิดปกติก่อนติดตั้งและส่งมอบระบบขึ้นสู่สภาพแวดล้อมเพื่อใช้งานจริง

2.2 แบบจำลองข้อมูลหลายมิติและการออกแบบสกีมา

แบบจำลองข้อมูลหลายมิติ (Dimensional Modeling) เป็นเทคนิคการจำลองโครงสร้างข้อมูลเชิงตรรกะที่คิดค้นโดย Ralph Kimball มีวัตถุประสงค์เพื่อสนับสนุนการวิเคราะห์ข้อมูลและการตอบสนองต่อคำสั่ง Query เชิงวิเคราะห์ (OLAP Query) ได้อย่างรวดเร็ว โครงสร้างพื้นฐานประกอบด้วยตารางหลัก 2 ประเภท ได้แก่ ตารางข้อเท็จจริง (Fact Table) และ ตารางมิติ (Dimension Table)

2.2.1 แนวคิดและโครงสร้างของ Fact Table (ตารางข้อเท็จจริง)

Fact Table คือตารางศูนย์กลางของแบบจำลอง ทำหน้าที่จัดเก็บตัวเลขผลการดำเนินงานเชิงปริมาณ (Performance Measures หรือ Metrics) ที่เกิดขึ้นจากการดำเนินกิจกรรมหรือธุรกรรมทางธุรกิจ โดยมีองค์ประกอบและหลักการออกแบบที่สำคัญดังนี้

1. คำแถลงระดับความละเอียดของข้อมูล

Grain Statement คือข้อกำหนดหรือคำนิยามร่วมกันที่ระบุว่า "ข้อมูล 1 แถวใน Fact Table หมายถึงเหตุการณ์หรือตัวแทนของสิ่งใดในโลกความเป็นจริง" ถือเป็นขั้นตอนพื้นฐานที่สำคัญที่สุดในการออกแบบ Fact Table

- หาก Grain ไม่ได้รับการกำหนดอย่างรัดกุม จะทำให้เกิดความสับสนในการเชื่อมโยงมิติข้อมูล เกิดปัญหาข้อมูลซ้ำซ้อน และทำให้ผลการคำนวณตัวชี้วัดคลาดเคลื่อน
- แนวปฏิบัติที่ดีของการออกแบบคลังข้อมูล ควรกำหนดให้ Fact Table บันทึกข้อมูลที่ระดับละเอียดที่สุดเท่าที่ระบบต้นทางสามารถเก็บได้ (Lowest Atomic Grain) เช่น รายการสินค้าแต่ละบรรทัดในใบเสร็จ (Line-item level) เนื่องจากข้อมูลที่ละเอียดที่สุดจะมีความยืดหยุ่นสูง สามารถนำไปจัดกลุ่ม (Roll-up) หรือคัดกรองในมุมมองใดก็ได้ในอนาคตโดยไม่สูญเสียความละเอียด

2. ประเภทของ Fact Table ทั้ง 4 แบบ

การจำแนกประเภทของ Fact Table เป็นไปตามลักษณะและพฤติกรรมการเกิดขึ้นของข้อมูลทางธุรกิจ ได้แก่

1. **Transaction Fact Table:** บันทึกเหตุการณ์ที่เกิดขึ้น ณ จุดเวลาใดเวลาหนึ่ง ข้อมูลจะถูกบันทึกเพิ่มขึ้นเรื่อยๆ (Append-only) โดยไม่มีการแก้ไขแถวเดิม เช่น รายการขายสินค้าแต่ละรายการ หรือการรูดบัตรเครดิต
2. **Periodic Snapshot Fact Table:** บันทึกภาพตัดสถานะรวม ณ ช่วงเวลาสั้นรอบที่สม่ำเสมอ เช่น สิ้นวัน สิ้นสัปดาห์ หรือสิ้นเดือน เพื่อดูแนวโน้มหรือสถานะของระบบ เช่น ยอดสินค้าคงคลังสิ้นวัน หรือ ยอดเงินฝากคงเหลือสิ้นเดือน
3. **Accumulating Snapshot Fact Table:** ใช้สำหรับกระบวนการทางธุรกิจที่มีวงจรชีวิตชัดเจนและผ่านหลายเหตุการณ์สำคัญโดย 1 แถวในตารางแทน 1 ชิ้นงานตลอดกระบวนการ และจะมีการอัปเดตแถวเดิมซ้ำเมื่อผ่านไปยังสถานะถัดไป เช่น กระบวนการสั่งซื้อจนถึงส่งมอบสินค้า (รับออเดอร์ -> ชำระเงิน -> จัดส่ง -> ส่งมอบ) มักใช้เพื่อวัดระยะเวลาความล่าช้าของแต่ละช่วง
4. **Factless Fact Table:** ตารางข้อเท็จจริงที่ไม่มีตัวเลขเชิงปริมาณ (Numeric Measures) ให้คำนวณ มีเพียงคีย์อ้างอิงไปยังตารางมิติต่างๆ เพื่อบันทึกการเกิดขึ้นของเหตุการณ์ เช่น การบันทึกการเข้าชั้นเรียนของนักศึกษา หรือตารางบันทึกความครอบคลุมของเงื่อนไข เช่น สินค้าที่ร่วมรายการโปรโมชั่น

3. คุณสมบัติการรวมคำนวณของตัววัด

Measures คือแอตทริบิวต์ตัวเลขใน Fact Table ซึ่งมีคุณสมบัติทางคณิตศาสตร์ในการรวมผล (Aggregation) แตกต่างกัน 3 รูปแบบ:

- **Additive (บวกได้ทุกมิติ):** ตัววัดที่สามารถหาผลรวมได้อย่างถูกต้องสมบูรณ์ข้ามทุกมิติ เช่น ยอดเงินขาย, ปริมาณสินค้า, หรือจำนวนครั้งของการเกิดเหตุการณ์
- **Semi-additive (บวกได้บางมิติ):** ตัววัดที่สามารถรวมผลข้ามมิติส่วนใหญ่ได้ แต่ ห้ามบวกข้ามมิติเวลา โดยเด็ดขาด มักเป็นข้อมูลระดับคงเหลือ ณ จุดเวลาใดเวลาหนึ่ง เช่น ยอดเงินในบัญชีธนาคาร หรือ จำนวนสินค้าคงเหลือในคลัง ซึ่งการรวมข้ามเวลาต้องใช้วิธีหาค่าเฉลี่ย (AVG) หรือค่า ณ วันสิ้นสุดงวด (LAST_VALUE)

- **Non-additive (รวมผลบวกไม่ได้เลย):** ตัววัดที่ไม่สามารถนำมาบวกกันได้ในทุกมิติ มักเป็นอัตราส่วน, ร้อยละ, หรือค่าเฉลี่ยต่อหน่วย เช่น อัตรากำไร ตามหลักการออกแบบห้ามบันทึกค่าร้อยละสำเร็จรูปไว้ใน Fact Table แต่ต้องเก็บตัวตั้งและตัวหารที่เป็น Additive แยกกัน แล้วนำมาหารกันในชั้นการคำนวณ เพื่อป้องกันปัญหาความคลาดเคลื่อนจากการหาค่าเฉลี่ยของค่าเฉลี่ย

4. คีย์และการจัดการคอลัมน์พิเศษใน Fact Table

- ในการสร้างความสัมพันธ์ระหว่าง Fact Table และ Dimension Tables จะต้องใช้ **Surrogate Key** (ตัวเลขจำนวนเต็มที่ระบบคลังข้อมูลสร้างขึ้นใหม่แบบไม่สื่อความหมาย) เป็น Primary Key ของ Dimension และนำไปเป็น Foreign Key ใน Fact Table เสมอ เพื่อหลีกเลี่ยงการพึ่งพา **Natural Key** (รหัสธุรกิจเดิมจากระบบต้นทาง) ซึ่งช่วยเพิ่มความเร็วในการเชื่อมโยงตาราง (Join Performance) และรองรับการบันทึกประวัติศาสตร์เมื่อข้อมูลมีการเปลี่ยนแปลง (SCD Type 2)
- **มิติเสื่อมถอย (Degenerate Dimension: DD):** แอตทริบิวต์เชิงบรรยายระดับธุรกรรมที่เกิดขึ้นร่วมกับเหตุการณ์ แต่ไม่มีคุณลักษณะแวดล้อมอื่นเพียงพอที่จะแยกออกไปสร้างเป็นตาราง Dimension ใหม่ จึงถูกจัดเก็บฝังอยู่ใน Fact Table โดยตรงเพื่อใช้เป็นตัวกรองหรือใช้อ้างอิงย้อนกลับไปยังเอกสารต้นทาง เช่น หมายเลขใบแจ้งหนี้ (Invoice Number), หรือหมายเลขเอกสารอ้างอิง
- **คอลัมน์สำหรับการตรวจสอบย้อนกลับ (Audit Columns):** คอลัมน์ที่เพิ่มเข้าไปในตาราง Fact เพื่อประโยชน์ด้านการกำกับดูแลข้อมูล (Data Lineage) เช่น วันที่และเวลาที่โหลดข้อมูลเข้าสู่คลังข้อมูล (load_timestamp) และรหัสรอบการทำงานของระบบ ETL (batch_id)

2.2.2 แนวคิดตารางมิติ (Dimension Table) และ Conformed Dimensions

1. บทบาทของตารางมิติในการให้บริบท (Context)

Dimension Table ทำหน้าที่เก็บข้อมูลเชิงบรรยายเพื่อตอบคำถามเกี่ยวกับบริบทแวดล้อมของเหตุการณ์ ได้แก่ ใคร (Who), ทำอะไร (What), ที่ไหน (Where), และเมื่อไหร่ (When) แอตทริบิวต์ในตารางมิติส่วนใหญ่เป็นข้อความ (Text) หรือรหัสหมวดหมู่ ซึ่งนำไปใช้ประโยชน์ในระบบรายงาน 3 ประการหลัก ได้แก่:

1. ใช้เป็น เงื่อนไขในการจำกัดขอบเขตข้อมูล (Filtering/Slicing) ผ่านคำสั่ง WHERE

- 2. ใช้เป็น แกนในการจัดกลุ่มข้อมูล (Grouping/Dicing) ผ่านคำสั่ง GROUP BY
- 3. ใช้เป็น ป้ายกำกับในการแสดงผล (Reporting Labels) บนหัวตารางหรือแกนของกราฟ

2. มิติรวม (Conformed Dimensions) และบัสเมทริกซ์ (Bus Architecture)

- **Conformed Dimensions:** คือตารางมิติที่ได้รับการออกแบบให้มีโครงสร้าง นิยาม และมาตรฐานของข้อมูลเหมือนกันทุกประการ เพื่อให้สามารถนำไปแชร์และเชื่อมโยงกับ Fact Table หลายๆ ตารางในองค์กรได้ เช่น มิติวันเวลา (Date Dimension) หรือมิติตำแหน่งสถานที่ (Location Dimension) ซึ่งการมี Conformed Dimensions ทำให้ระบบสามารถวิเคราะห์เปรียบเทียบข้อมูลข้ามสายงาน (Drill-across) ได้โดยไม่เกิดความขัดแย้งของข้อมูล
- **Data Warehouse Bus Matrix:** แผนภาพตารางสองมิติตามแนวคิดของ Ralph Kimball ที่ใช้แสดงการจับคู่ระหว่างกระบวนการทางธุรกิจ (Business Processes / Fact Tables) ในแถวแนวนอน กับมิติข้อมูลที่ใช้ร่วมกัน (Conformed Dimensions) ในคอลัมน์แนวตั้ง เพื่อใช้เป็นพิมพ์เขียวหลักในการวางแผนขยายระบบคลังข้อมูลทีละส่วนอย่างเป็นระบบ

2.2.3 รูปแบบสกีมา: Star Schema เทียบกับ Snowflake Schema

ในการจัดโครงสร้างความสัมพันธ์ระหว่าง Fact Table และ Dimension Tables ในระดับกายภาพ มีรูปแบบสถาปัตยกรรมหลัก 2 รูปแบบ

มิติ / เปรียบเทียบ	Star Schema	Snowflake Schema
โครงสร้างตารางมิติ	Denormalized	Normalized
จำนวนชั้นการเชื่อมโยง (Join)	1 ชั้น (Single-Level Join): เชื่อมตรงกับ Dimension Table แต่ละตารางโดยตรง	หลายชั้น (Multi-Level Joins): ต้องเชื่อมโยงตารางมิติต่อกันเป็นทอดๆ เพื่อเข้าถึงข้อมูล
ประสิทธิภาพการควิรี (OLAP)	สูงกว่า: คำสั่ง SQL เรียบง่าย ฐานข้อมูลทำการ Join น้อยครั้ง ทำให้ประมวลผลได้รวดเร็วกว่า	ต่ำกว่า: ต้องประมวลผลคำสั่ง Join ซับซ้อนหลายตาราง ทำให้ความเร็วในการควิรีลดลง
ความซับซ้อนในการใช้งาน BI	ง่าย ผู้ใช้งานและเครื่องมือ Business Intelligence เข้าใจโครงสร้างได้ง่าย	ซับซ้อน ผู้ใช้งานต้องเข้าใจความสัมพันธ์เชิงลำดับชั้นของตารางมิติน้อย
การใช้พื้นที่จัดเก็บข้อมูล	ใช้พื้นที่มากกว่าเล็กน้อยเนื่องจากไม่มีการแยกตารางลดความซ้ำซ้อน	ใช้พื้นที่จัดเก็บน้อยกว่าเนื่องจากข้อมูลถูก Normalized

หลักการคัดเลือกสกีมาในคลังข้อมูลสมัยใหม่

ในอดีต Snowflake Schema เคยได้รับความนิยมเนื่องจากพื้นที่จัดเก็บบนฮาร์ดดิสก์มีราคาสูง แต่ในบริบทของระบบคลังข้อมูลสมัยใหม่ โดยเฉพาะคลังข้อมูลบนระบบคลาวด์ที่มีสถาปัตยกรรมการจัดเก็บข้อมูลแบบแยกตามคอลัมน์ (Columnar Storage) และมีระบบการบีบอัดข้อมูลประสิทธิภาพสูง Star Schema ถือเป็นรูปแบบมาตรฐานที่แนะนำให้เลือกใช้เป็นหลัก เนื่องจาก:

1. การจัดเก็บแบบ Columnar สามารถบีบอัดข้อมูลข้อความที่ซ้ำซ้อนได้อย่างมีประสิทธิภาพสูง ทำให้ข้อได้เปรียบเรื่องการประหยัดเนื้อที่ของ Snowflake Schema แทบไม่มีผลต่างอย่างมีนัยสำคัญ
2. Star Schema ช่วยลดจำนวนการ Join ของตารางลง ส่งผลให้การสืบค้นและรวมผลสถิติบนข้อมูลขนาดใหญ่ทำได้รวดเร็วอย่างชัดเจน ซึ่งตอบโจทย์การใช้งานร่วมกับเครื่องมือแสดงผลสารสนเทศเชิงภาพ (Data Visualization) และการดึงข้อมูลเพื่อนำไปวิเคราะห์ขั้นสูง

2.3 การจัดการมิติข้อมูลที่มีการเปลี่ยนแปลงตามเวลา

ในความเป็นจริง ข้อมูลในตารางมิติสามารถเกิดการเปลี่ยนแปลงได้ตามกาลเวลา ปรากฏการณ์นี้เรียกว่า Slowly Changing Dimensions (SCD) ซึ่งถือเป็นหนึ่งในหัวข้อเชิงกลยุทธ์ที่สำคัญที่สุดของการจำลองข้อมูลหลายมิติ

2.3.1 นิยามและปัญหาของ SCD

Slowly Changing Dimensions (SCD) หมายถึง เทคนิคและระเบียบวิธีในการจัดการกับข้อมูลแอตทริบิวต์ในตารางมิติที่มีการเปลี่ยนแปลงอย่างช้าๆ หรือไม่สม่ำเสมอ เพื่อควบคุมว่าระบบคลังข้อมูลจะตอบสนองต่อการเปลี่ยนแปลงนั้นอย่างไร และจะรักษาความถูกต้องของประวัติศาสตร์ในอดีตไว้อย่างไร การเลือกประเภทของ SCD จึงเป็นการตัดสินใจเพื่อตอบคำถามทางธุรกิจว่า "เราต้องการดูข้อมูลในอดีตตามบริบท ณ เวลาที่เกิดเหตุจริง (As-Was) หรือต้องการดูสถิติในอดีตตามมุมมองบริบทปัจจุบัน (As-Is)"

2.3.2 ประเภทของ SCD

ตามทฤษฎีของ Ralph Kimball การจัดการ SCD สามารถแบ่งออกได้เป็น 6 รูปแบบหลัก ดังนี้:

1. SCD Type 0: มิติคงที่ถาวร (Fixed Dimension) : ข้อมูลที่บันทึกแล้วจะ ถูกล็อกห้ามเปลี่ยนแปลงโดยเด็ดขาด ไม่ว่าเวลาจะผ่านไปเท่าใดก็ตาม

- **กรณีการใช้งาน:** ข้อมูลข้อเท็จจริงทางกายภาพหรือข้อมูลตั้งต้น เช่น วันที่ในปฏิทิน (full_date, day_of_week), เพศกำเนิด, หรือรหัสประจำตัวประชาชน
- **ข้อดี/ข้อเสีย:** โครงสร้างเรียบง่ายที่สุด ไม่ต้องมีตรรกะใน ETL แต่ไม่ยืดหยุ่นหากข้อมูลต้นทางบันทึกมาผิดพลาดตั้งแต่แรก

2. SCD Type 1: การเขียนทับข้อมูลเดิม (Overwrite) เมื่อข้อมูลในระบบต้นทางเปลี่ยนแปลง ระบบจะทำการ **เขียนทับ (UPDATE)** ค่าเดิมในตารางมิติทันที โดยไม่มีการเก็บประวัติค่าเก่าไว้

- **กรณีการใช้งาน:** ข้อมูลที่เปลี่ยนแปลงเนื่องจากการแก้ไขคำสะกดผิด (Typo Correction) หรือข้อมูลที่ผู้บริหารไม่สนใจประวัติในอดีต
- **ข้อดี/ข้อเสีย:** ทำงานได้ง่าย เร็ว ไม่ทำให้ขนาดของตารางมิติขยายตัว แต่จะสูญเสียข้อมูลประวัติศาสตร์โดยสิ้นเชิง ไม่สามารถสืบค้นย้อนหลังได้ว่าในอดีตเคยมีค่าเป็นอย่างไร

3. SCD Type 2: การเก็บประวัติศาสตร์สมบูรณ์ (Full History) เมื่อข้อมูลเปลี่ยนแปลง ระบบจะ **ไม่แก้ไขแถวเดิม** แต่จะเพิ่มแถวใหม่ (INSERT New Row) เข้าไปในตารางมิติ โดยอาศัยคอลัมน์พิเศษ 4 ตัว ได้แก่:

1. surrogate_key: คีย์เทียมใหม่สำหรับระบุแต่ละเวอร์ชันของระเบียบ
2. start_date (หรือ valid_from): วันที่ข้อมูลเวอร์ชันนี้เริ่มมีผลใช้งาน
3. end_date (หรือ valid_to): วันที่ข้อมูลเวอร์ชันนี้สิ้นสุดผลบังคับใช้ (หากยังใช้งานอยู่จะใส่ค่า NULL หรือ '9999-12-31')
4. is_current: ระบุว่าเป็นข้อมูลเวอร์ชันปัจจุบันหรือไม่ (TRUE / FALSE)

- **ตัวอย่างโครงสร้าง:**

customer_sk (PK)	customer_code	region	start_date	end_date	is_current
101	C001	Bangkok	2021-01-01	2023-12-31	False

102	C001	Chiang Mai	2024-01-01	9999-12-31	True
-----	------	------------	------------	------------	------

- ข้อดี/ข้อเสีย: รักษาความถูกต้องตามประวัติศาสตร์ได้อย่างสมบูรณ์แบบ 100% แต่โครงสร้างตารางจะขยายตัวอย่างรวดเร็ว กระบวนการ ETL มีความซับซ้อน และ Fact Table ต้องเชื่อมด้วย Surrogate Key เสมอ

4. SCD Type 3: การเก็บประวัติแบบจำกัด (Limited History) ไม่เพิ่มแถวใหม่ แต่ใช้วิธี **เพิ่มคอลัมน์ใหม่** ในตารางเดิม เพื่อเก็บค่าก่อนหน้า (Previous Value)

- ตัวอย่างโครงสร้าง:

customer_code	customer_name	current_region	previous_region	last_updated
C001	Somchai	Chiang Mai	Bangkok	2024-01-01

- ข้อดี/ข้อเสีย: เปรียบเทียบข้อมูล "ปัจจุบัน vs ก่อนหน้า" ได้ทันทีในแถวเดียวโดยไม่ต้อง Join หลายแถว แต่จะเก็บประวัติได้จำกัดเพียง 1-2 เวอร์ชันเท่านั้น หากมีการย้ายครั้งที่ 3 ประวัติครั้งแรกจะสูญหาย

5. SCD Type 4: การแยกตารางประวัติศาสตร์ (Separate History Table) แยกตารางออกเป็น 2 ตารางอย่างเด็ดขาด ดังนี้

- Current Dimension Table:** เก็บเฉพาะข้อมูลเวอร์ชันปัจจุบันเท่านั้น (1 แถวต่อ 1 เอนทิตี) เพื่อให้ระบบหน้าบ้านหรือรายงานประจำวันคิวรีได้เร็วที่สุด
 - Historical Dimension Table:** ทำหน้าที่เป็น Audit Log บันทึกทุกเวอร์ชันที่มีการเปลี่ยนแปลงพร้อมระบุ valid_from และ valid_to
- ข้อดี/ข้อเสีย: เพิ่มความเร็วในการสืบค้นข้อมูลล่าสุดได้อย่างมาก เหมาะกับระบบขนาดใหญ่ แต่เพิ่มภาระในการดูแลรักษาตารางถึง 2 ตาราง

6. SCD Type 6: รูปแบบผสมผสาน โดยรวมคุณสมบัติของ Type 1, Type 2, และ Type 3 เข้าด้วยกัน

- เพิ่มแถวใหม่เมื่อมีการเปลี่ยนแปลง (Type 2) พร้อมระบุ start_date, end_date, is_current
- มีคอลัมน์เก็บค่าในอดีต (Type 3) เช่น previous_value

- เมื่อเกิดการเปลี่ยนแปลง จะนำค่าล่าสุดไป **เขียนทับ (Type 1)** ในคอลัมน์ **current_value** ของทุกแถวในอดีต ของเอนทิตีนั้น
- **ข้อดี/ข้อเสีย:** ให้ความยืดหยุ่นสูงสุดในการทำ BI ผู้ใช้งานสามารถเลือกดูรายงานได้ทั้งมุมมอง "ณ เวลาเกิดเหตุ" (As-Was) และมุมมอง "ตามสถานะปัจจุบัน" (As-Is) ได้ในตารางเดียว แต่กระบวนการ ETL จะมีความซับซ้อนสูงสุด

ตารางสรุปเปรียบเทียบคุณสมบัติของ SCD แต่ละประเภท

SCD Type	การจัดเก็บ	การเก็บประวัติ	ความซับซ้อนของตาราง / ETL	ผลกระทบต่อพื้นที่จัดเก็บ	ความเหมาะสมในการใช้งาน
0	ห้ามแก้ไข	ไม่ได้	ต่ำที่สุด	คงที่	ข้อมูลปฏิทิน วันเกิด รหัสประจำตัวที่ไม่เปลี่ยนแปลง
1	เขียนทับค่าเดิม	ไม่ได้	ต่ำ	คงที่	แก้ไขค่าสะกดผิด ข้อมูลที่ไม่สนใจประวัติ
2	เพิ่มแถวใหม่	ไม่จำกัด (Full)	ปานกลางถึงสูง	ขยายตัวตามการเปลี่ยนแปลง	งานวิเคราะห์ประวัติศาสตร์ที่ต้องการความแม่นยำสูง
3	เพิ่มคอลัมน์	จำกัด	ต่ำ	ขยายตามจำนวนคอลัมน์	วิเคราะห์เปรียบเทียบค่าปัจจุบันกับค่าก่อนหน้า
4	แยกตารางประวัติ	เต็มรูปแบบ	สูง (ดูแล 2 ตาราง)	ปานกลาง	ระบบที่ต้องการความเร็วในการคิวรีข้อมูลล่าสุด
6	รูปแบบผสม	เต็มรูปแบบ + ยืดหยุ่น	สูงมาก	ขยายตัวสูง	องค์กรขนาดใหญ่ที่ต้องการทั้งมุมมอง As-Was และ As-Is

2.4 กระบวนการเคลื่อนย้ายและแปลงข้อมูล (ETL/ELT Data Pipeline)

กระบวนการเคลื่อนย้ายและแปลงข้อมูลทำหน้าที่นำข้อมูลจากระบบปฏิบัติการต้นทางเข้าสู่คลังข้อมูล โดยมีแนวคิดทางทฤษฎีที่สำคัญดังนี้

1. การเปรียบเทียบสถาปัตยกรรม ETL กับ ELT

- **ETL (Extract, Transform, Load):** ดึงข้อมูลออกมา ทำการแปลงและทำความสะอาดบนเซิร์ฟเวอร์ ประมวลผลภายนอกก่อนที่จะโหลดข้อมูลที่พร้อมใช้เข้าสู่คลังข้อมูล เหมาะกับระบบที่ข้อมูลต้นทางมีรูปแบบไม่แน่นอนและต้องการควบคุมความสะอาดอย่างเข้มงวด
- **ELT (Extract, Load, Transform):** ดึงข้อมูลและโหลดเข้าสู่พื้นที่จัดเก็บบนคลังข้อมูลก่อน จากนั้นจึงใช้พลังการประมวลผลแบบขนานของคลังข้อมูลสมัยใหม่ในการแปลงข้อมูลผ่านคำสั่ง SQL เหมาะกับข้อมูลขนาดใหญ่บนระบบคลาวด์

2. กลยุทธ์การนำเข้าข้อมูล: Full Load เทียบกับ Incremental Load

- **Full Load (การโหลดทั้งหมด):** การอ่านและโหลดข้อมูลต้นทางใหม่ทั้งหมดทุกรอบ นิยมใช้กับข้อมูลประวัติศาสตร์ตั้งแต่ต้น (Initial Load) หรือตารางมิติ (Dimension) ที่มีขนาดเล็ก
- **Incremental Load (การโหลดเฉพาะส่วนต่าง):** การดึงเฉพาะข้อมูลที่เพิ่มขึ้นใหม่หรือมีการเปลี่ยนแปลงนับจากรอบก่อนหน้า โดยอาศัยตัวชี้วัดจุดตัดข้อมูล (Watermark) เช่น คอลัมน์วันเวลาที่ปรับปรุงล่าสุด (Updated Timestamp) ร่วมกับช่วงเวลาย้อนหลัง (Lookback Window) เพื่อประหยัดทรัพยากรการประมวลผล

3. คุณสมบัติความคงสภาพของผลลัพธ์ (Idempotency) และ Late-Arriving Data

- **Idempotency:** กฎเหล็กของการสร้างท่อข้อมูล ที่กำหนดว่า การส่งรันทะบวนการซ้ำด้วยชุดข้อมูลเดิมก็ครั้งก็ตาม ผลลัพธ์ในคลังข้อมูลจะต้องคงเดิมเสมอ ไม่เกิดข้อมูลซ้ำซ้อน มักใช้กลยุทธ์การลบข้อมูลตามช่วงเวลาก่อนแล้วจึงแทรกใหม่ (Delete-and-Insert)
- **Late-Arriving Data:** ปรากฏการณ์ที่ข้อมูลธุรกรรมในอดีตเพิ่งถูกส่งเข้ามาในคลังข้อมูลช้ากว่าปกติ หรือมีการอัปเดตสถานะย้อนหลัง ท่อข้อมูลจะต้องมีกลไกตรวจสอบเพื่อปรับปรุงข้อมูลในแถวเดิมให้ถูกต้อง

2.5 คุณภาพข้อมูลและการตรวจสอบความถูกต้อง (Data Quality & Validation Framework)

หลักการสำคัญของคลังข้อมูลคือ "Pipeline PASS ไม่ได้แปลว่า Business PASS" (แม้ระบบจะโหลดข้อมูลผ่านโดยไม่มีข้อผิดพลาดทางเทคนิค แต่ข้อมูลอาจไม่ถูกต้องตามตรรกะทางธุรกิจ) จึงต้องมีกระบวนการตรวจสอบดังนี้:

1. มิติของคุณภาพข้อมูล 6 ด้าน (The 6 Data Quality Dimensions)

1. **Accuracy (ความถูกต้องตรงกับจริง):** ตัวเลขและข้อเท็จจริงต้องตรงกับสิ่งที่เกิดขึ้นในโลกความเป็นจริง
2. **Completeness (ความครบถ้วน):** คอลัมน์ที่จำเป็นต้องไม่มีค่าว่างที่ผิดปกติ
3. **Consistency (ความสอดคล้องกัน):** ข้อมูลที่มีความสัมพันธ์กันต้องไม่ขัดแย้งกันเอง เช่น ข้อมูลในรหัสเดียวกันต้องระบุเขตพื้นที่ตรงกัน
4. **Validity (ความถูกต้องตามกฎหมาย):** ค่าของข้อมูลต้องตกอยู่ในขอบเขตหรือรูปแบบที่กำหนด เช่น วันที่ต้องไม่ใช่วันในอนาคต, พิกัดละติจูดต้องอยู่ตามช่วงพิกัดจริง
5. **Uniqueness (ความไม่ซ้ำซ้อน):** ข้อมูลหลักต้องไม่ซ้ำกันตามระดับความละเอียด (Grain) ที่กำหนด
6. **Timeliness (ความสดใหม่ทันการ):** ข้อมูลต้องได้รับการประมวลผลและพร้อมใช้งานตามข้อตกลงระยะเวลาส่งมอบ

2. สถาปัตยกรรมจุดตรวจคุณภาพข้อมูลแบบหลายชั้น (Multi-Layer Quality Gates)

- **Source Layer Gate:** ตรวจสอบความถูกต้องของโครงสร้างไฟล์และชนิดข้อมูลตามข้อตกลง (Data Contract)
- **Staging Layer Gate:** ทำการสำรวจข้อมูล (Data Profiling) และคัดกรองค่าที่อยู่นอกช่วงที่กำหนด (Domain Validation)
- **Core DW Gate:** ตรวจสอบความสมบูรณ์ของการเชื่อมโยงคีย์ (Referential Integrity) และการคำนวณตัววัด
- **Data Mart Gate:** ตรวจสอบความสอดคล้องของตัวเลขรวม (Reconciliation) ก่อนนำไปแสดงผลบนรายงาน

3. กลยุทธ์การตอบสนองต่อข้อมูลที่ผิดปกติ (Anomaly Handling)

- **Block (ระงับการทำงาน):** หยุดการทำงานของท่อข้อมูลทันทีเมื่อพบข้อผิดพลาดระดับวิกฤต (Critical Errors)
- **Quarantine (กักกันข้อมูล):** คัดแยกเฉพาะแถวข้อมูลที่มีปัญหาออกไปเก็บไว้ในตารางกักกันชั่วคราว เพื่อให้ผู้รับผิดชอบตรวจสอบ โดยไม่ให้หลุดเข้าไปทำลายความน่าเชื่อถือในคลังข้อมูลหลัก
- **Warn (แจ้งเตือน):** ให้ระบบทำงานต่อไปได้ แต่ส่งข้อความแจ้งเตือนเมื่อพบความผิดปกติระดับต่ำ

2.6 การสรุปผลข้อมูล เลเยอร์ตัวชี้วัด และการวิเคราะห์หลายมิติ

1. การสรุปผลข้อมูลล่วงหน้าและหลุมพรางทางสถิติ (Average-of-Averages Pitfall)

- **การทำ Pre-aggregation:** การคำนวณและสรุปผลข้อมูลไว้ล่วงหน้าในรูปแบบของตารางสรุป (Summary Tables) ช่วยลดภาระการประมวลผลคำสั่ง GROUP BY บนข้อมูลระดับหลายล้านแถว ทำให้ระบบรายงานตอบสนองได้อย่างรวดเร็ว
- กฎสำคัญในการสร้างตารางสรุปผลคือ **ห้ามหาค่าเฉลี่ยจากค่าเฉลี่ยหรือคำนวณผลรวมจากค่าร้อยละ** สำเร็จรูป เพราะจะทำให้ค่าน้ำหนักทางสถิติผิดเพี้ยน การคำนวณอัตราส่วนใดๆ จะต้องคำนวณจากผลรวมของตัวตั้งหารด้วยผลรวมของตัวหารเสมอ เช่น

$$\text{Correct Ratio} = \frac{\sum \text{Success Events}}{\sum \text{Total Events}} \times 100$$

2. แนวคิดตัวชี้วัดผลการดำเนินงาน (KPI) และชั้นตัวชี้วัดกลาง (Metric Layer)

- **ตัวชี้วัดผลการดำเนินงาน (Key Performance Indicator: KPI)** คือตัวเลขเชิงปริมาณที่ใช้ประเมินความสำเร็จและประสิทธิภาพของกระบวนการทางธุรกิจในแต่ละหมวดหมู่ข้อมูล ในทางวิศวกรรมคลังข้อมูล KPI จะเป็นตัวกำหนดโดยตรงว่าคลังข้อมูลจะต้องจัดเก็บข้อมูลตัวใดเป็น **Fact (ตัววัด)** เช่น หากธุรกิจต้องการวัดยอดขายหรือยอดการเกิดเหตุ Fact Table จะต้องมียอดตัวเลขเชิงปริมาณมารองรับเสมอ
- **หลักการคัดเลือก KPI ที่ดี (ตามมาตรฐานคลังข้อมูล):**

1. ต้องวัดได้เป็นตัวเลขจริง (Quantifiable): มีค่าเป็นเชิงปริมาณที่ชัดเจน ไม่คลุมเครือ
 2. ต้องสอดคล้องกับเป้าหมายทางธุรกิจ (Goal-Aligned): สะท้อนประสิทธิภาพการทำงานจริง
 3. ต้องสามารถวัดซ้ำได้อย่างสม่ำเสมอ (Repeatable): คำนวณตามรอบเวลาได้ เช่น รายวัน หรือ รายเดือน
- ปัญหาเมื่อไม่มีมาตรฐาน KPI: ในองค์กรทั่วไป หากไม่มีการกำหนดนิยามกลาง จะเกิดปัญหา "สูตรไม่ตรงกัน = รายงานไม่ตรงกัน = ความสับสน" เช่น นักวิเคราะห์คนหนึ่งเขียนสูตรใน Excel ด้วยวิธีหนึ่ง ทีมทำแดชบอร์ดเขียนคำสั่งคำนวณอีกแบบหนึ่ง และโปรแกรมเมอร์เขียน SQL ด้วยเงื่อนไขที่ต่างออกไป ทำให้ตัวเลขผลลัพธ์ที่รายงานต่อผู้บริหารขัดแย้งกันเอง
 - การแก้ปัญหาด้วยชั้นตัวชี้วัดกลาง (Metric Layer / Semantic Layer): คือแนวคิดในการสร้างชั้นโครงสร้างเสมือน เพื่อทำหน้าที่เป็นศูนย์กลางในการนิยามสูตรคำนวณ KPI ทั้งหมดไว้ที่โค้ดส่วนกลางเพียงแห่งเดียว เพื่อให้เครื่องมือแสดงผล, แอปพลิเคชันแดชบอร์ด, หรือแบบจำลอง Machine Learning ดึงสูตรคำนวณเดียวกันไปประมวลผลโดยอัตโนมัติ ซึ่งช่วยลดความซ้ำซ้อน จัดความขัดแย้งของตัวเลข และรองรับการกำกับดูแลข้อมูล (Data Governance) ระดับองค์กรได้อย่างมีประสิทธิภาพ

3. การดำเนินการเชิงวิเคราะห์หลายมิติ (OLAP Operations)

การวิเคราะห์ข้อมูลบนแบบจำลองลูกบาศก์หลายมิติ (OLAP Cube) อาศัย 4 การดำเนินการหลัก

- Roll-up: ลดทอนรายละเอียดเพื่อดูภาพรวมที่กว้างขึ้น (เช่น จากระดับวัน → ระดับเดือน → ระดับปี)
- Drill-down: เจาะลึกจากภาพรวมลงไปสู่รายละเอียดระดับย่อย (เช่น จากระดับเขต → ระดับพื้นที่ย่อย)
- Slice & Dice: ตัดแบ่งข้อมูลเฉพาะมุมมองที่สนใจ (Slice: กรองมิติเดียว, Dice: กรองหลายมิติพร้อมกัน)
- Pivot: หมุนสลับแกนข้อมูลเพื่อเปลี่ยนมุมมองในการแสดงผล

2.7 ทฤษฎีการวิเคราะห์เชิงพื้นที่-เวลาและการแสดงภาพข้อมูล

การวิเคราะห์ข้อมูลเชิงพื้นที่และเวลา (Spatial-Temporal Analysis) เป็นระเบียบวิธีทางสถิติที่มุ่งเน้นการศึกษาเหตุการณ์ที่มีตัวแปรระบุตำแหน่งทางภูมิศาสตร์ (Spatial Attributes เช่น พิกัดละติจูด-ลองจิจูด หรือขอบเขตพื้นที่) ควบคู่กับตัวแปรระบุเวลา (Temporal Attributes เช่น วันที่ ชั่วโมง หรือฤดูกาล)

1. **การวิเคราะห์จุดความหนาแน่นสูง (Hotspot Analysis):** เป็นเทคนิคทางภูมิสารสนเทศเพื่อระบุบริเวณที่มีการกระจุกตัวของเหตุการณ์หนาแน่นผิดปกติทางสถิติเมื่อเทียบกับการกระจายตัวแบบสุ่ม ช่วยให้ผู้มีอำนาจตัดสินใจสามารถระบุพื้นที่เสี่ยงเพื่อวางแผนรับมือได้อย่างมีประสิทธิภาพ
2. **การแสดงผลผ่านแผนที่ความร้อน (Heatmap Visualization):** เป็นวิธีการแสดงผลข้อมูลเชิงพื้นที่โดยการแปลงข้อมูลจุดพิกัดที่หนาแน่นให้อยู่ในรูปของการไล่ระดับเฉดสีโดยสีที่มีความเข้มสูง (เช่น สีแดง) จะเป็นตัวแทนของบริเวณที่มีความหนาแน่นของเหตุการณ์สูง ช่วยให้ผู้ใช้งานสามารถทำความเข้าใจรูปแบบการกระจายตัวของข้อมูลขนาดใหญ่ได้อย่างรวดเร็วโดยไม่ต้องอ่านค่าพิกัดตัวเลขที่ละจุด

2.8 เทคโนโลยีและเครื่องมือที่ใช้ในการพัฒนา

ในการพัฒนาระบบคลังข้อมูล โครงการนี้ได้เลือกใช้ชุดเครื่องมือมาตรฐานที่ครอบคลุมตั้งแต่การจำลองสภาพแวดล้อม การจัดเก็บ การแปลงโครงสร้างข้อมูล การควบคุมท่อข้อมูลอัตโนมัติ ไปจนถึงการแสดงผลเชิงวิเคราะห์ โดยจำแนกตามบทบาทหน้าที่ได้ดังนี้

2.8.1 โครงสร้างพื้นฐานและการจำลองสภาพแวดล้อม

Docker และ Docker Compose ทำหน้าที่เป็นแพลตฟอร์มจำลองสภาพแวดล้อมเสมือน เพื่อรวบรวมทุกเซอร์วิสของคลังข้อมูลให้อยู่ในชุดคำสั่งเดียวกัน โดยมี**คุณสมบัติสำคัญ** ป้องกันปัญหาความไม่เข้ากันของสภาพแวดล้อมระหว่างเครื่องของผู้พัฒนา สามารถสั่งเปิด-ปิด และกำหนดการเชื่อมต่อเครือข่ายภายในระหว่าง Database, Airflow, และ Metabase ได้อย่างสะดวกรวดเร็ว

2.8.2 ระบบจัดเก็บคลังข้อมูลและการจัดการ

- **PostgreSQL 16** เป็นฐานข้อมูลหลักสำหรับจัดเก็บคลังข้อมูล รองรับข้อมูลตั้งแต่ชั้นข้อมูลดิบจนถึงมาร์ตข้อมูล โดยรองรับการแบ่งเลเยอร์ข้อมูลด้วย **PostgreSQL Schemas** (เช่น raw, staging, core_dw, data_marts) รวมถึงมีระบบดัชนี (Indexing), การจัดการพาร์ติชัน (Partitioning), และรองรับฟังก์ชันการคำนวณขั้นสูงของมาตรฐาน ANSI SQL

- **pgAdmin 4** เป็นเครื่องมือบริหารจัดการฐานข้อมูลผ่านเว็บ ใช้สำหรับตรวจสอบสถานะของฐานข้อมูล ตรวจสอบโครงสร้างตาราง (DDL), และรันคำสั่ง SQL Ad-hoc เพื่อทดสอบผลลัพธ์ในระหว่างการพัฒนา

2.8.3 เครื่องมือแปลงข้อมูลและควบคุมคุณภาพ (Transformation & Modeling Engine)

- **dbt Core** (Data Build Tool) เป็นหัวใจสำคัญของสถาปัตยกรรมแบบ ELT (Extract, Load, Transform) ทำหน้าที่แปลงข้อมูล (T) ภายในคลังข้อมูลให้เป็นแบบจำลอง Star Schema และดูแลคุณภาพข้อมูล
- ฟังก์ชันหลักที่นำมาประยุกต์ใช้:
 - **Data Modeling:** เขียนแบบจำลองข้อมูลด้วย SQL ผสมผสานกับภาษา Jinja templating เพื่อสร้างตาราง Fact และ Dimension
 - **Materializations:** รองรับการสร้างออบเจกต์ในฐานข้อมูลหลายรูปแบบ ได้แก่ view, table, และ incremental (สำหรับการโหลดเฉพาะข้อมูลใหม่ ช่วยประหยัดเวลาและพลังประมวลผล)
 - **SCD Type 2 Handling:** ใช้คำสั่ง dbt snapshot ในการตรวจจับการเปลี่ยนแปลงและบันทึกประวัติศาสตร์ย้อนหลังแบบอัตโนมัติ
 - **Data Quality Testing:** ระบบทดสอบคุณภาพข้อมูลในตัว ทั้ง Generic Tests (unique, not_null, relationships, accepted_values) และ Singular SQL Tests เพื่อเป็นด่านตรวจคุณภาพก่อนนำข้อมูลไปใช้งาน
 - **Lineage Graph & Documentation:** สร้างแผนผังเส้นทางการไหลของข้อมูล (Data Lineage Graph) และพจนานุกรมข้อมูล (Data Catalog) อัตโนมัติ

2.8.4 ระบบควบคุมและจัดลำดับท่อข้อมูล (Workflow Orchestration)

- **Apache Airflow (เวอร์ชัน 3.x):** เป็นแพลตฟอร์มบริหารจัดการเวิร์กโฟลว์ ทำหน้าที่กำหนดตารางเวลา และควบคุมลำดับการทำงานของท่อข้อมูล (Data Pipeline) โดยสามารถกำหนดกระบวนการทำงานในรูปแบบ DAG (Directed Acyclic Graph) ด้วยภาษา Python จัดการการทำงานแบบอัตโนมัติตามรอบเวลา (Schedule Trigger) เช่น การดึงและอัปเดตข้อมูลประจำวัน รวมถึงมีระบบตรวจสอบข้อผิดพลาด (Failure Handling), การลองใหม่อัตโนมัติ (Retry Mechanism), และระบบแจ้งเตือน
- **Astronomer Cosmos** เป็นโมดูลเชื่อมต่อที่ทำงานบน Apache Airflow ทำหน้าที่แปลงโมเดลของ dbt ทั้งหมดให้กลายเป็น Tasks ย่อยบน Airflow DAG โดยอัตโนมัติ ทำให้ผู้ดูแลระบบสามารถมองเห็นและควบคุมกระบวนการแปลงข้อมูลของ dbt ที่ละตารางบนหน้าต่าง Airflow UI ได้อย่างสมบูรณ์

2.8.5 เครื่องมือวิเคราะห์เชิงธุรกิจและการแสดงผลข้อมูล (BI & Visualization)

- **Metabase** เครื่องมือสร้างรายงานและภาพสารสนเทศเชิงธุรกิจ (Business Intelligence & Visualization Tool) แบบ Open-source โดยสามารถ
 - รองรับการเชื่อมต่อกับคลังข้อมูลโดยตรง เพื่อสร้าง Interactive Dashboards และแผนภูมิแสดงตัวชี้วัด (KPIs)
 - รองรับการวิเคราะห์ข้อมูลหลายมิติแบบ OLAP Operations ได้แก่ การเจาะลึกดูข้อมูลย่อย (Drill-down), การดูภาพรวมระดับสูง (Roll-up), และการกรองตัดแบ่งข้อมูล (Slice & Dice)
 - รองรับการแสดงผลเชิงแผนที่ (Geographic Map / Pin Map / Heatmap) สำหรับข้อมูลที่มีพิกัดทางภูมิศาสตร์

ตารางสรุปบทบาทและหน้าที่ของชุดเครื่องมือ (Tools & Technologies Summary)

เครื่องมือ / เทคโนโลยี	หมวดหมู่สถาปัตยกรรม	บทบาทหน้าที่ในโครงการ
Docker Compose	Infrastructure	จำลองสภาพแวดล้อมและควบคุมการทำงานของ Container ทั้งหมด
PostgreSQL 16	Storage Layer	ฐานข้อมูลจัดเก็บคลังข้อมูล (Staging, Fact, Dimension, Data Marts)
pgAdmin 4	Database Tool	หน้าต่างจัดการ ตรวจสอบ และทดสอบคิวรีฐานข้อมูล
dbt Core	Transformation Layer	แปลงโครงสร้าง Star Schema, ทำ Incremental Load, SCD Type 2 และ Data Quality Tests

Apache Airflow	Orchestration Layer	ตั้งเวลาและควบคุมลำดับการรัน Pipeline ประจำวันแบบอัตโนมัติ
Astronomer Cosmos	Orchestration Tool	ผสาน dbt Project เข้าสู่ Airflow DAG เพื่อติดตาม Lineage และจัดการ Error
Metabase	Presentation Layer	สร้างแดชบอร์ด KPI, Heatmap แผนที่ และรองรับการทำ OLAP (Drill-down / Slice & Dice)

บทที่ 3

การวิเคราะห์ ออกแบบ และพัฒนาระบบ

3.1 ข้อมูลที่ใช้ในการศึกษาและการสำรวจเบื้องต้น

การออกแบบและพัฒนาระบบคลังข้อมูลอาชญากรรม (Crime Data Warehouse) จำเป็นต้องอาศัยการทำความเข้าใจโครงสร้าง ธรรมชาติ และคุณภาพของข้อมูลต้นทางอย่างลึกซึ้ง โดยโครงงานนี้ใช้ข้อมูลที่เปิดเผยต่อสาธารณะจากพอร์ทัลข้อมูลเปิดของนครชิคาโก (City of Chicago Data Portal) ซึ่งประกอบด้วย ชุดข้อมูลการเกิดเหตุอาชญากรรมหลัก (Primary Dataset) ทำงานร่วมกับ ชุดข้อมูลอ้างอิงเชิงพื้นที่และรหัสมาตรฐาน (Reference & Boundary Lookup Datasets) เพื่อนำมาบูรณาการเข้าด้วยกันในคลังข้อมูล

3.1.1 ชุดข้อมูลการเกิดเหตุอาชญากรรมหลัก (Primary Crime Dataset)

- ชื่อชุดข้อมูล: Crimes - 2001 to Present
- หน่วยงานเจ้าของข้อมูล: กรมตำรวจชิคาโก (Chicago Police Department: CPD)
- ระบบต้นทาง: ระบบ CLEAR (*Citizen Law Enforcement Analysis and Reporting*)
- แหล่งเข้าถึงข้อมูล: [City of Chicago Data Portal \(Dataset ID: ijzp-q8t2\)](#)
- ความถี่ในการปรับปรุงข้อมูล (Update Frequency): ปรับปรุงข้อมูลเป็น รายวัน (Daily)
- ขอบเขตและปริมาณข้อมูล: จัดเก็บข้อมูลย้อนหลังตั้งแต่ปี ค.ศ. 2001 จนถึงปัจจุบัน มีปริมาณข้อมูลสะสมมากกว่า 8 ล้านระเบียน (8,000,000+ rows) ขนาดไฟล์ข้อมูลดิบ (CSV) ประมาณ 2.2–2.5 Gigabytes
- นโยบายความเป็นส่วนตัวของข้อมูล (Data Redaction): กรมตำรวจชิคาโกมีการบดบังข้อมูลตำแหน่งที่อยู่จริงของผู้เสียหาย โดยแสดงผลเฉพาะระดับช่วงถนน (Block Level) เช่น 043XX S WOOD ST และ พิกัดละติจูด-ลองจิจูดจะถูกขยับให้อยู่บนช่วงถนนเดียวกัน เพื่อป้องกันการระบุตัวตนของเหยื่ออาชญากรรม

พจนานุกรมข้อมูลต้นทางของชุดข้อมูลหลัก (Primary Source Data Dictionary)

ชุดข้อมูลหลักประกอบด้วยข้อมูลจำนวน 22 คอลัมน์ ดังแสดงในตารางที่ 3.1

ตารางที่ 3.1 พจนานุกรมข้อมูลของชุดข้อมูลอาชญากรรมหลัก (Chicago Crimes: 2001 to Present)

ลำดับ	ชื่อคอลัมน์	ชื่อฟิลด์ใน API	ชนิดข้อมูล	คำอธิบายรายละเอียด
1	ID	id	Number (Integer)	รหัสระบุรายการเหตุการณ์ที่ไม่ซ้ำกันของระบบต้นทาง
2	Case Number	case_number	Text (VARCHAR)	หมายเลขคดีของกรมตำรวจชิคาโก (RD Number) ประจำแต่ละเหตุการณ์
3	Date	date	Floating Timestamp	วันและเวลาที่เกิดเหตุการณ์อาชญากรรม (บางคดีเป็นการประมาณการเวลา)
4	Block	block	Text (VARCHAR)	ที่อยู่แบบย่อในระดับช่วงถนนของจุดเกิดเหตุเพื่อรักษาความเป็นส่วนตัว
5	IUCR	iucr	Text (VARCHAR)	รหัสความผิดตามมาตรฐาน Illinois Uniform Crime Reporting (4 หลัก)
6	Primary Type	primary_type	Text (VARCHAR)	หมวดหมู่อาชญากรรมหลักของรหัส IUCR (เช่น THEFT, BATTERY)
7	Description	description	Text (VARCHAR)	คำอธิบายย่อของรหัส IUCR ที่ระบุพฤติกรรมคดีโดยละเอียด
8	Location Description	location_description	Text (VARCHAR)	คำอธิบายลักษณะทางกายภาพของสถานที่เกิดเหตุ
9	Arrest	arrest	Checkbox (Boolean)	สถานะที่ระบุว่าเจ้าหน้าที่สามารถจับกุมผู้กระทำผิดได้หรือไม่ (True/False)
10	Domestic	domestic	Checkbox (Boolean)	ระบุว่าเป็นคดีความรุนแรงในครอบครัวตามกฎหมายรัฐอิลลินอยส์หรือไม่ (True/False)
11	Beat	beat	Text (VARCHAR)	รหัสเขตพื้นที่ตรวจย่อยที่เกิดเหตุการณ์ (หน่วยพื้นที่เล็กสุดของสายตรวจ)
12	District	district	Text (VARCHAR)	หมายเลขเขตสถานีตำรวจที่รับผิดชอบพื้นที่เกิดเหตุ (ชิคาโกมี 22 เขต)
13	Ward	ward	Number (Integer)	หมายเลขเขตเลือกตั้งสภาเทศบาลเมืองชิคาโก (City Council District: 1-50)

14	Community Area	community_area	Text (VARCHAR)	หมายเลขพื้นที่ชุมชนทางการเมืองชิคาโก (มีทั้งหมด 77 ชุมชน)
15	FBI Code	fbi_code	Text (VARCHAR)	รหัสจำแนกประเภทอาชญากรรมตามมาตรฐาน FBI NIBRS
16	X Coordinate	x_coordinate	Number (Float)	พิกัดแนวราบในระบบ State Plane Illinois East NAD 1983 projection
17	Y Coordinate	y_coordinate	Number (Float)	พิกัดแนวตั้งในระบบ State Plane Illinois East NAD 1983 projection
18	Year	year	Number (Integer)	ปี ค.ศ. ที่เกิดเหตุการณ์
19	Updated On	updated_on	Floating Timestamp	วันและเวลาที่ข้อมูลระเบียนนี้ได้รับการปรับปรุงล่าสุดในระบบต้นทาง
20	Latitude	latitude	Number (Float)	ค่าพิกัดละติจูดของตำแหน่งเกิดเหตุ (ปรับย้ายให้อยู่บนบล็อกร่วมกัน)
21	Longitude	longitude	Number (Float)	ค่าพิกัดลองจิจูดของตำแหน่งเกิดเหตุ (ปรับย้ายให้อยู่บนบล็อกร่วมกัน)
22	Location	location	Location (Composite)	ข้อมูลพิกัดทางภูมิศาสตร์แบบคู่ลำดับ (Latitude, Longitude) สำหรับทำแผนที่

3.1.2 ชุดข้อมูลอ้างอิงและตารางเสริม

เนื่องจากชุดข้อมูลอาชญากรรมหลักมีการจัดเก็บข้อมูลแอตทริบิวต์เชิงพื้นที่และประเภทคดีในรูปแบบของ **รหัสตัวเลข (Codes)** เท่านั้น (เช่น มีเพียงเลขเขต Community Area 1 ถึง 77 หรือรหัสสถานีดำรวจ) หากนำไปแสดงผลบนแดชบอร์ดโดยตรง ผู้ใช้งานจะไม่ทราบชื่อชุมชนหรือชื่อสถานีดำรวจจริง ดังนั้น ระบบคลังข้อมูลจึงนำชุดข้อมูลอ้างอิงอย่างเป็นทางการจาก Chicago Data Portal จำนวน 5 ชุดข้อมูล มาทำการบูรณาการร่วมกัน (Data Integration) ดังแสดงในตารางที่ 3.2

ตารางที่ 3.2 สรุปชุดข้อมูลอ้างอิงทางการ (Reference Lookups) บน Chicago Data Portal ที่นำมาบูรณาการ

ชุดข้อมูลอ้างอิง	ข้อมูลสำคัญที่นำมาสังกัด	ประโยชน์และการนำไปใช้ในคลังข้อมูล
1. IUCR Codes	IUCR, PRIMARY DESCRIPTION, SECONDARY DESCRIPTION, INDEX CRIME, ACTIVE	- นำรหัส 4 หลักมาสังกัดคอลัมน์ INDEX CRIME (เพื่อระบุว่าคดีใดเป็นคดีอุกฉกรรจ์ร้ายแรงตามมาตรฐานสากล) - ใช้ตรวจสอบความถูกต้องของคดีในตาราง dim_crime_type
2. Police Beats (current)	BEAT, BEAT_NUM, DISTRICT, SECTOR	- สร้างลำดับชั้นทางสายตรวจ: Beat → Sector → District (เนื่องจากในไฟล์หลักไม่มีข้อมูล Sector สายตรวจ) - ใช้ประกอบการสร้างตาราง dim_location
3. Police Districts (current)	DIST_NUM, DIST_LABEL, ADD RESS, PHONE	แปลงรหัสตัวเลขสถานีตำรวจให้เป็น ชื่อสถานีตำรวจจริง (District Name) เช่น "11th District - Harrison", "1st District - Central" เพื่อแสดงผลบนแดชบอร์ด
4. Wards (2023 - current)	WARD, ALDERMAN, WARD_PH ONE	ให้ข้อมูลขอบเขตการปกครองสภาเทศบาล 50 เขต ใช้เปรียบเทียบสถิติคดีในมิติการบริหารส่วนท้องถิ่นและการกำหนดนโยบาย
5. Community Areas (current)	AREA_NUMBE, COMMUNITY, GEOMETRY	แปลงรหัสตัวเลขในไฟล์หลักให้เป็น ชื่อชุมชนจริง เช่น "Loop", "Austin", "Near North Side" ทำให้การวิเคราะห์เชิงพื้นที่ที่มีความหมายเข้าใจง่าย

3.2 การรวบรวมและวิเคราะห์ความต้องการของระบบ

การรวบรวมและวิเคราะห์ความต้องการของข้อมูล ถือเป็นขั้นตอนเริ่มต้น (Step 1) ของวงจรชีวิตการพัฒนากล้องข้อมูล เพื่อทำความเข้าใจบริบททางธุรกิจ กำหนดขอบเขตการทำงานไม่ให้เกิดปัญหาการขยายขอบเขตงานเกินจำเป็น (Scope Creep) และใช้เป็นพิมพ์เขียวหลักในการออกแบบสถาปัตยกรรมแบบจำลองข้อมูลในขั้นตอนถัดไป โดยมีรายละเอียดดังนี้

3.2.1 กลุ่มผู้ใช้งานและเป้าหมาย (Stakeholders & Personas)

ระบบคลังข้อมูลนี้ได้รับการออกแบบขึ้นเพื่อตอบสนองความต้องการของผู้ใช้งานหลัก 4 กลุ่ม:

1. **ผู้บังคับการตำรวจ:** มีเป้าหมายในการติดตามสถิติภาพรวมระดับเมือง (Macro View) เพื่อประเมินผลสัมฤทธิ์ของการบังคับใช้กฎหมาย วิเคราะห์แนวโน้มอาชญากรรมระยะยาว และใช้เป็นข้อมูลประกอบการตัดสินใจกำหนดนโยบายความปลอดภัยสาธารณะ
2. **ฝ่ายวางแผนกำลังพลและสายตรวจ:** มีเป้าหมายในการปฏิบัติงานเชิงยุทธวิธี (Tactical View) โดยต้องการทราบตำแหน่งจุดเสี่ยง (Hotspots) และช่วงเวลาที่มีอัตราการเกิดเหตุสูง เพื่อจัดสรรกำลังพลและวางแผนเส้นทางลาดตระเวนของรถสายตรวจในแต่ละกะได้อย่างตรงจุด
3. **นักวิเคราะห์อาชญากรรม:** มีเป้าหมายในการสืบค้นข้อมูลเหตุการณ์คดีเชิงลึก (Atomic Data) และวิเคราะห์ความเชื่อมโยงของข้อมูล เพื่อนำข้อมูลสถิติที่สะอาดและเป็นมาตรฐานไปใช้เป็นตัวแปร (Features) ในการพัฒนาแบบจำลองพยากรณ์ความเสี่ยง
4. **เจ้าหน้าที่ผังเมือง:** มีเป้าหมายในการนำข้อมูลสถิติคดีเชิงพื้นที่และลักษณะสถานที่เกิดเหตุ (Location Description) ไปใช้ปรับปรุงสภาพแวดล้อมทางกายภาพของเมือง เช่น หากพบว่าจุดใดเกิดเหตุคดีปล้นหรือทำร้ายร่างกายบ่อยครั้งในเวลากลางคืน จะนำข้อมูลไปสนับสนุนการเพิ่มไฟส่องสว่างบนถนน หรือติดตั้งกล้องวงจรปิด (CCTV) เพิ่มเติมเพื่อลดความเสี่ยงในอนาคต

3.2.2 คำถามทางธุรกิจที่ระบบต้องตอบ (Business Questions)

คลังข้อมูลถูกออกแบบขึ้นเพื่อตอบโจทย์คำถามสำคัญทางธุรกิจ 3 มิติหลัก ได้แก่:

- มิติเชิงพื้นที่ (Spatial Questions):
 - พื้นที่เขตตรวจย่อย (Beat) หรือชุมชน (Community Area) ไต เป็นจุดความเสี่ยงสูง (Hotspot) ที่เกิดเหตุอาชญากรรมหนาแน่นที่สุด
 - การกระจายตัวของคดีอาชญากรรมแต่ละประเภท (เช่น คดีโจรกรรมทรัพย์สิน กับ คดีใช้ความรุนแรง) ในแต่ละเขตมีรูปแบบต่างกันอย่างไร
 - อาชญากรรมแต่ละประเภทมักเกิดขึ้นในสถานที่ลักษณะใดมากที่สุด (เช่น บนถนน ที่พักอาศัย หรือปั้มน้ำมัน)

- มิติเชิงเวลา (Temporal Questions):
 - ช่วงเวลาใดในรอบวัน (ชั่วโมง/กะตรวจ) หรือวันใดในรอบสัปดาห์ ที่มีโอกาสเกิดเหตุร้ายหรือคดีปล้นทรัพย์มากที่สุด (Peak Hours)
 - วันใดในสัปดาห์ หรือเดือนใด ที่สถิติคดีพุ่งสูงขึ้นอย่างมีนัยสำคัญ
 - แนวโน้มการเกิดอาชญากรรมภาพรวมของเมืองชิคาโกในรอบ 5-10 ปีที่ผ่านมา มีทิศทางลดลงหรือเพิ่มขึ้น (Trend & YoY Growth)
- มิติประสิทธิภาพการบังคับใช้กฎหมาย (Performance Questions):
 - ประเภทคดีอาชญากรรมแบบใด (Crime Type / IUCR) ที่มีอัตราการจับกุมผู้กระทำผิดได้น้อย (Low Arrest Rate) ซึ่งจำเป็นต้องได้รับการปรับปรุงแผนการสืบสวน
 - คดีที่เกี่ยวข้องกับความรุนแรงในครอบครัว (Domestic Violence) มีสัดส่วนคิดเป็นร้อยละเท่าใดของคดีทั้งหมด และมักเกิดขึ้นในพื้นที่ใดเป็นพิเศษ

3.2.3 การระบุ Subject Area และ Business Process

ตามหลักการของ Ralph Kimball คณะผู้จัดทำได้เชื่อมโยงหมวดหมู่ข้อมูลใหญ่ (Subject Area) เข้ากับกิจกรรมที่เป็นคำกริยาที่ก่อให้เกิดข้อมูลจริงในระบบ (Business Process) ทั้งหมด 3 ส่วน:

1. Subject Area 1: การเฝ้าระวังและติดตามเหตุอาชญากรรม
 - **Business Process:** การรับแจ้งและบันทึกเหตุการณ์อาชญากรรม (*Reporting Crime Incident*) ซึ่งเป็นกิจกรรมที่เกิดขึ้นเมื่อประชาชนแจ้งเหตุ หรือเจ้าหน้าที่ตำรวจสายตรวจตรวจพบในพื้นที่ ทำให้เกิดระเบียนคดีใหม่ในระบบ CLEAR
2. Subject Area 2: การบังคับใช้กฎหมายและการจับกุม
 - **Business Process:** การจับกุมผู้กระทำผิด (*Arresting Offender*) เป็นกิจกรรมที่เจ้าหน้าที่ตำรวจควบคุมตัวผู้ต้องหาได้ ส่งผลให้สถานะคดีเปลี่ยนเป็น Arrest = True ใช้ประเมิน

ประสิทธิภาพการทำงานและการตอบสนองของเจ้าหน้าที่ตำรวจ เพื่อสนับสนุนการประเมินนโยบายและการปฏิบัติงาน

3. Subject Area 3: การประเมินความเสี่ยงและจัดสรรทรัพยากรเชิงพื้นที่

- Business Process:** การสรุปประเมินความเสี่ยงและจัดสรรกำลังพลประจำรอบกะ (Evaluating Periodic Shift Risk) โดยนำข้อมูลสถิติที่ประมวลผลแล้วไปใช้จัดสรรรถสายตรวจ/เจ้าหน้าที่ให้ตรงจุด และส่งต่อให้แบบจำลอง Machine Learning ใช้พยากรณ์ความเสี่ยง

3.2.4 คำแถลงระดับความละเอียดของข้อมูล (Grain Statement)

การกำหนดความละเอียดของข้อมูลในตารางข้อเท็จจริงหลัก ถูกกำหนดไว้ที่ระดับย่อยที่สุด (Lowest Atomic Grain) คือ **1 แถวในตาราง แทน 1 รายงานเหตุการณ์อาชญากรรม (Individual Crime Incident Record) ที่เกิดขึ้นจริง ณ พิกัดสถานที่และจุดเวลาหนึ่งๆ ในเมืองชิคาโก**

- เหตุผลทางเทคนิค: การเก็บที่ระดับ Atomic Grain ช่วยให้ระบบมีความยืดหยุ่นสูงสุด สามารถนำข้อมูลพิกัดละติจูด-ลองจิจูดไปคำนวณแผนที่ความร้อน (Heatmap), สรุปยอดคดีรวม, คำนวณอัตราการจับกุม, และนำเข้าเป็น Feature ของแบบจำลอง Machine Learning ได้โดยไม่สูญเสียความละเอียดของข้อมูลในอดี

3.2.5 การนิยามตัวชี้วัด (KPI Definitions) และการสร้าง Metric Layer

เพื่อเป็นมาตรฐานกลางในการคำนวณ ตัวชี้วัดทั้งหมดจึงถูกกำหนดสูตรไว้ดังแสดงในตารางที่ 3.2.1

ตารางที่ 3.2.1 นิยามตัวชี้วัดและสูตรคำนวณมาตรฐาน (KPI Definitions)

รหัส KPI	ชื่อตัวชี้วัด	นิยามความหมายทางธุรกิจ	สูตรการคำนวณทางสถิติ	คุณสมบัติการรวม (Additivity)
KPI-01	Total Incident Count	จำนวนคดีที่เกิดขึ้นทั้งหมด ใช้สะท้อนปริมาณภาระงานและความเสี่ยง	$\sum(\text{incident_count})$ (โดยแต่ละแถวมีค่าเท่ากับ 1)	Fully Additive (รวมข้ามเวลา, พื้นที่, ประเภทคดีได้)
KPI-02	Arrest Count	จำนวนคดีที่สามารถจับกุมผู้กระทำความผิดได้	$\sum(\text{arrest_flag})$ (ค่า 1 เมื่อจับกุมได้, 0 เมื่อจับไม่ได้)	Fully Additive

KPI-03	Arrest Rate (%)	สัดส่วนในการจับกุมคดีเพื่อประเมินประสิทธิภาพการทำงานของตำรวจ	$\left(\frac{\sum \text{arrest_flag}}{\sum \text{incident_count}} \right) \times 100$	Non-Additive (คำนวณจากผลรวมตัวตั้งหารผลรวมตัวหาร)
KPI-04	Domestic Violence Count	จำนวนคดีที่เกิดจากความรุนแรงในครอบครัว	$\sum(\text{domestic_flag})$ (ค่า 1 เมื่อเป็นคดีครอบครัว, 0 เมื่อไม่ใช่)	Fully Additive
KPI-05	Domestic Violence Ratio (%)	สัดส่วนคดีความรุนแรงในครอบครัวต่อคดีทั้งหมด	$\left(\frac{\sum \text{domestic_flag}}{\sum \text{incident_count}} \right) \times 100$	Non-Additive
KPI-06	High-Severity Crime Count	จำนวนคดีอุกฉกรรจ์ร้ายแรง (Index Crimes / Violent Crimes) ตามเกณฑ์ FBI	$\sum (\text{CASE WHEN fbi_code IN ('01A','02','03','04A','04B') THEN 1 ELSE 0})$	Fully Additive

3.2.6 การจัดทำ Data Warehouse Bus Matrix

การจัดทำตาราง Bus Matrix ตามสถาปัตยกรรมของ Ralph Kimball เพื่อแสดงการเชื่อมโยงระหว่าง Business Processes ของทั้ง 3 Subject Areas กับมิติข้อมูลที่ใช้ร่วมกัน (Conformed Dimensions) โดยมีตารางข้อเท็จจริงหลัก fact_crime_incident ทำหน้าที่เป็นศูนย์กลางเพียงตารางเดียว ดังแสดงในตารางที่ 3.2.2

ตารางที่ 3.2.2 Data Warehouse Bus Matrix ของระบบคลังข้อมูลอาชญากรรมเมืองชิคาโก

Subject Area	Business Process	dim_date	dim_time	dim_location	dim_crime_type	dim_location_type
การเฝ้าระวัง, ติดตามเหตุอาชญากรรม	การรับแจ้งเหตุอาชญากรรม (Report Incident)	✓	✓	✓	✓	✓
การบังคับใช้กฎหมายและการจับกุม	การเข้าจับกุมผู้กระทำความผิด (Arrest Offender)	✓	✓	✓	✓	✓

การประเมินความเสี่ยง, จัดสรรทรัพยากรเชิงพื้นที่	การวิเคราะห์ความเสี่ยงเชิงพื้นที่ (Analyze Risk)	✓	✓	✓	✓	✓
---	--	---	---	---	---	---

3.3 การออกแบบแบบจำลองข้อมูลหลายมิติ (Dimensional Data Modeling)

การจำลองข้อมูลในโครงการนี้ใช้สถาปัตยกรรมแบบ **Star Schema** เพื่อให้การสืบค้นข้อมูลเชิงวิเคราะห์ (OLAP) บนข้อมูลอาชญากรรมกว่า 8 ล้านแถวทำได้อย่างรวดเร็วและเป็นมิตรต่อการทำแดชบอร์ด ประกอบด้วย **1 ตารางข้อเท็จจริง (Fact Table)** และ **5 ตารางมิติ (Dimension Tables)** ดังแสดงในแผนภาพความสัมพันธ์:

3.3.1 การออกแบบตารางข้อเท็จจริง (fact_crime_incident)

- **ระดับความละเอียด (Grain):** กำหนดไว้ที่ Atomic Grain (1 แถว ต่อ 1 เหตุการณ์อาชญากรรมจริง)
- **คีย์เชื่อมโยง (Foreign Keys):** ใช้ Surrogate Key (ชนิดจำนวนเต็ม Integer) เชื่อมต่อไปยังตารางมิติทั้ง 5 มิติ เพื่อประสิทธิภาพสูงสุดในการประมวลผลคำสั่ง Join
- **มิติเสื่อมถอย (Degenerate Dimensions: DD):** จัดเก็บ case_number (หมายเลขคดี RD Number) และ source_id ไว้ในตาราง Fact โดยตรง เพื่อใช้ในการค้นหาและอ้างอิงกลับไปยังระบบต้นทาง โดยไม่ต้องสร้างเป็นตารางมิติแยก
- **ตัววัดเชิงปริมาณ (Measures):** จัดเก็บเฉพาะ Raw Additive Metrics เท่านั้น เพื่อให้สามารถรวมผล (SUM) ข้ามทุกมิติได้อย่างถูกต้อง ได้แก่
 - incident_count (มีค่าเป็น 1 เสมอ ใช้สำหรับนับจำนวนคดีรวม)
 - arrest_flag (ค่า 1 เมื่อจับกุมได้ และ 0 เมื่อยังจับไม่ได้ ใช้คำนวณยอดจับกุมและหาอัตราส่วน Arrest Rate)

- `domestic_flag` (ค่า 1 เมื่อเป็นคดีความรุนแรงในครอบครัว และ 0 เมื่อไม่ใช่)
- **คอลัมน์การกำกับดูแล (Audit Columns):** `source_updated_at` (ใช้ทำ Incremental Refresh) และ `dw_load_timestamp` (เวลาที่บันทึกลงคลังข้อมูล)

3.3.2 การออกแบบตารางมิติ (Dimension Tables)

ตารางมิติทั้ง 5 ตารางทำหน้าที่ให้บริบทแวดล้อมแก่เหตุการณ์อาชญากรรม โดยใช้ Surrogate Key เป็น Primary Key ทุกตาราง:

1. **dim_date (มิติปฏิทิน):** สร้างตารางปฏิทินมาตรฐาน โดยใช้ `date_key` ในรูปแบบตัวเลข YYYYMMDD (เช่น 20240927) ช่วยในการวิเคราะห์แนวโน้มรายวัน รายเดือน รายไตรมาส และเปรียบเทียบวันธรรมดากับวันหยุดสุดสัปดาห์
2. **dim_time (มิติเวลาในรอบวัน):** สกัดจากเวลาเกิดเหตุ เพื่อรองรับการวิเคราะห์ตามช่วงชั่วโมง (Hour of Day) และแบ่งกลุ่มตาม **กะสายตรวจของตำรวจ (Police Shifts)** ได้แก่ กะเช้า (08:00–16:00), กะบ่าย (16:00–24:00), และกะดึก (00:00–08:00)
3. **dim_location (มิติสถานที่และภูมิศาสตร์):** รวบรวมข้อมูลพิกัดและลำดับขั้นการปกครอง โดยบูรณาการข้อมูลรหัสในไฟล์คดีเข้ากับชุดข้อมูล Boundary Lookups ทำให้ได้ทั้ง **ชื่อสถานีตำรวจจริง (District Name)**, **ชื่อชุมชนจริง (Community Name)**, และ **Sector สายตรวจ**
4. **dim_crime_type (มิติการจำแนกประเภทคดี):** บูรณาการรหัส IUCR เข้ากับตารางมาสเตอร์ของ CPD ทำให้ทราบว่าคดีใดจัดเป็น `is_index_crime = True` (คดีอุกฉกรรจ์ร้ายแรงตามมาตรฐาน FBI) เพื่อใช้คำนวณดัชนีความรุนแรงของเมือง
5. **dim_location_type (มิติลักษณะสถานที่เกิดเหตุ):** สกัดค่าที่ไม่ซ้ำกันจากคอลัมน์ Location Description (เช่น STREET, APARTMENT, GAS STATION) ช่วยให้คัดกรองสถานที่เสี่ยงได้อย่างรวดเร็ว

3.3.3 ตารางสรุปพจนานุกรมข้อมูลคลังข้อมูล

ตารางที่ 3.3 สรุปโครงสร้างตารางในแบบจำลอง Star Schema

ชื่อตาราง	ประเภท ตาราง	ระดับความ ละเอียด (Grain)	คีย์หลัก (PK) / Foreign Keys (FK)	ตัวอย่างแอตทริบิวต์สำคัญ
fact_crime_incident	Fact	1 แถว ต่อ 1 เหตุการณ์ อาชญากรรม	PK: incident_key FK: date_key, time_key, location_key, crime_type_key, location_type_key	case_number, incident_count, arrest_flag, domestic_flag, source_updated_at
dim_date	Dimension	1 แถว ต่อ 1 วัน ปฏิทิน	PK: date_key (YYYYMMDD)	full_date, day_name, month_name, quarter, year, is_weekend
dim_time	Dimension	1 แถว ต่อ 1 นาทีในรอบวัน	PK: time_key (HHMM)	hour_24, minute, shift_name, period_name
dim_location	Dimension	1 แถว ต่อ 1 พื้นที่ตรวจ/พิกัด	PK: location_key	beat_code, district_name, community_name, ward_num, latitude, longitude
dim_crime_type	Dimension	1 แถว ต่อ 1 รหัสความผิด	PK: crime_type_key	iucr_code, primary_type, description, fbi_code, is_index_crime
dim_location_type	Dimension	1 แถว ต่อ 1 ประเภทสถานที่	PK: location_type_key	location_desc

3.4 กลยุทธ์การจัดการมิติข้อมูลที่มีการเปลี่ยนแปลงตามเวลา

ในการวิเคราะห์ข้อมูลอาชญากรรมย้อนหลังกว่า 20 ปี สภาพแวดล้อมเชิงมิตีย่อมมีการเปลี่ยนแปลงตามกาลเวลา คณะผู้จัดทำจึงได้นำทฤษฎี Slowly Changing Dimensions (SCD) จากบทที่ 2.3 มากำหนดเป็นกลยุทธ์การออกแบบระดับตาราง เพื่อรักษาความถูกต้องของข้อมูลประวัติศาสตร์และประสิทธิภาพในการประมวลผลดังนี้:

3.4.1 การนำ SCD Type 2 มาใช้กับมิติสถานที่ (dim_location)

มิติสถานที่และขอบเขตการปกครองมีพื้นฐานการเปลี่ยนแปลงเชิงโครงสร้างจริงในประวัติศาสตร์ของนครชิคาโก ได้แก่:

1. **การยุบรวมสถานีตำรวจ (Police District Consolidation):** ในเดือนธันวาคม ค.ศ. 2012 กรมตำรวจชิคาโก (CPD) ได้ปรับโครงสร้างองค์กรโดยยุบรวมสถานีตำรวจเขต 13 (Wood Street) เข้ากับเขต 12 (Near West) ส่งผลให้พื้นที่รับผิดชอบและสังกัดของเขตตรวจย่อย (Beat) เปลี่ยนแปลงไปอย่างเป็นทางการ
2. **การปรับแนวเขตเลือกตั้งสภาเมือง (Ward Redistricting):** มีการขีดเส้นแบ่งเขตสภาเทศบาล 50 เขตใหม่ทุกๆ 10 ปีตามผลสำมะโนประชากรสหรัฐฯ เช่น แผนที่เขต Ward ฉบับปี ค.ศ. 2023 ตามเทศบัญญัติสภาเมือง (City Council Ordinance O2022-1318)

เหตุผลและกลยุทธ์การออกแบบ (Design Strategy)

หากใช้การเขียนทับ (SCD Type 1) คดีทั้งหมดที่เกิดขึ้นก่อนปี 2012 จะถูกเปลี่ยนสังกัดเป็นสถานีตำรวจหรือเขตสภาเมืองในปัจจุบันทันที ซึ่งทำให้ข้อมูลสถิติผลงานย้อนหลังของผู้กำกับการสถานีตำรวจและตัวแทนชุมชนในอดีตเกิดความคลาดเคลื่อน ระบบจึงเลือกใช้ SCD Type 2 (Full History) โดยเพิ่มคอลัมน์ควบคุมประวัติศาสตร์ 4 คอลัมน์ในตาราง dim_location:

- location_key (INT, PK): Surrogate Key ประจำแต่ละเวอร์ชันของพื้นที่
- effective_start_date และ effective_end_date: กำหนดช่วงเวลาที่แนวเขตนั้นมีผลบังคับใช้จริง (หากเป็นเวอร์ชันปัจจุบันจะกำหนด effective_end_date = '9999-12-31')
- is_current (BOOLEAN): แฟล็กระบุเวอร์ชันล่าสุดสำหรับคิวรีสถานะปัจจุบัน (TRUE/FALSE)

เมื่อคิวรีเชื่อมโยงกับ fact_crime_incident ระบบจะทำการเชื่อมโยงตามช่วงเวลาเกิดเหตุ (Temporal Join: incident_date BETWEEN start_date AND end_date) ทำให้สถิติคดีในอดีตผูกกับสถานีตำรวจและเขตเลือกตั้งที่ถูกต้องตรงตามประวัติศาสตร์ ณ วันเกิดเหตุจริง (Point-in-Time Accuracy) 100%

3.4.2 การนำ SCD Type 1 มาใช้กับมิติประเภทคดี (dim_crime_type และ dim_location_type)

ในชุดข้อมูลต้นทาง รหัสคดี (IUCR Code) และลักษณะสถานที่ (Location Description) มีการเปลี่ยนแปลงเฉพาะกรณีการแก้ไขคำสะกดผิด (Typo Correction) หรือการปรับปรุงข้อความอธิบายย่อให้เป็นมาตรฐานกระชับขึ้น ซึ่งไม่ได้เปลี่ยนสาระสำคัญทางกฎหมาย

ดังนั้นคณะผู้จัดทำจึงใช้ **SCD Type 1 (Overwrite)** โดยการเขียนทับค่าเดิมในตารางต้นที่เมื่อพบการเปลี่ยนแปลงจากระบบต้นทาง ทำให้ชื่อเรียกประเภทคดีและสถานที่เกิดเหตุในรายงานทุกปีเป็นมาตรฐานเดียวกันทั้งระบบ โครงสร้างตารางไม่ขยายตัว และไม่เพิ่มภาระในการประมวลผลคำสั่ง Join

3.4.3 การจัดการข้อมูลที่มาช้ากว่ากำหนดในตารางข้อเท็จจริง (Late-Arriving Updates in Fact Table)

คณะผู้จัดทำได้จำแนกความแตกต่างระหว่างการเปลี่ยนแปลงของมิติ (SCD) ออกจากการเปลี่ยนแปลงสถานะของธุรกรรมใน Fact Table อย่างชัดเจน:

ในวันที่เกิดเหตุ เจ้าหน้าที่ตำรวจมักจะยังไม่สามารถจับกุมคนร้ายได้ทันที ข้อมูลจึงถูกบันทึกเป็น Arrest = False แต่เมื่อการสืบสวนคืบหน้าและสามารถจับกุมคนร้ายได้ในสัปดาห์ถัดมา ระบบ CLEAR จะส่งข้อมูลคดีเดิมที่มีการปรับสถานะเป็น Arrest = True เข้ามาใหม่ พร้อมระบุเวลาในคอลัมน์ Updated On การเปลี่ยนแปลงนี้ **ไม่ใช่ SCD** (เพราะไม่ใช่การเปลี่ยนคุณลักษณะของตารางมิติ) แต่จัดเป็น **Late-Arriving Fact Update**


- กลยุทธ์การจัดการในท่อข้อมูล (ETL Logic):

1. ใช้คอลัมน์ Updated On เป็น Watermark ตรวจสอบเฉพาะแถวที่มีการแก้ไขย้อนหลัง
2. ใช้กลยุทธ์ **Incremental Refresh แบบ Delete-and-Insert** (หรือ Merge/Upsert) โดยอ้างอิงจากคีย์ระบุคดี (case_number หรือ source_id)
3. ระบบจะทำการลบแถวเดิมใน fact_crime_incident แล้วแทรกแถวใหม่ที่มีสถานะ arrest_flag = 1 เข้าไปแทนที่

ซึ่งผลลัพธ์จะทำให้ระบบมีคุณสมบัติ **Idempotency** (รันซ้ำแล้วข้อมูลไม่เบิ้ล) สถิติอัตราการจับกุม (Arrest Rate) ในอดีตได้รับการปรับปรุงให้เป็นปัจจุบัน และไม่เกิดแถวข้อมูลคดีย้ำซ้อนในคลังข้อมูล

3.5 การออกแบบกระบวนการเคลื่อนย้ายและแปลงข้อมูล

ระบบคลังข้อมูลนี้เลือกใช้สถาปัตยกรรมแบบ **ELT (Extract, Load, Transform)** โดยใช้ **Apache Airflow** เป็นตัวควบคุมลำดับงาน, **PostgreSQL 16** เป็นฐานข้อมูลจัดเก็บหลัก, และ **dbt Core (Data Build Tool)** เป็นเครื่องมือแปลงข้อมูลและสร้างแบบจำลองภายในคลังข้อมูล



3.5.1 การแบ่งเลเยอร์การจัดเก็บข้อมูล (Data Layers)

โครงสร้างฐานข้อมูลบน PostgreSQL ถูกแบ่งแยกหน้าที่ด้วย Schema ออกเป็น 3 เลเยอร์หลัก:

- raw_staging (Staging Layer):** ทำหน้าที่เป็นพื้นที่พักข้อมูลดิบ คงสภาพโครงสร้างและชนิดข้อมูลจากไฟล์ CSV ต้นทาง (22 คอลัมน์) พร้อมเพิ่มคอลัมน์ระบบ (`_loaded_at`, `_batch_id`) สำหรับตรวจสอบที่มา (Lineage)
- core_dw (Warehouse Layer):** เก็บแบบจำลองข้อมูล Star Schema ที่ผ่านการทำความสะอาด กำหนด Surrogate Keys จัดการ SCD Type 2 และกำกับความสัมพันธ์ของ Foreign Keys
- data_marts (Presentation Layer):** เก็บตารางสรุปผลลัพธ์ (Summary Tables) และวิวเชิงวิเคราะห์เพื่อส่งมอบตัวเลข KPI ให้แก่ระบบแดชบอร์ดโดยเฉพาะ

3.5.2 กลยุทธ์การนำเข้าข้อมูล (Data Ingestion Strategy)


- **การนำเข้าข้อมูลย้อนหลัง (Initial Full Load):** โหลดข้อมูลประวัติศาสตร์อาชญากรรมสะสม 8 ล้านแถว (ตั้งแต่ปี 2001) เข้าสู่ raw_staging และสั่งรันโมเดล dbt ครั้งแรกเพื่อสร้างตาราง Star Schema ตั้งต้น
- **การปรับปรุงข้อมูลประจำวัน (Daily Incremental Refresh):**
 - ระบบจะดึงเฉพาะข้อมูลคดีใหม่หรือคดีที่มีการแก้ไขสถานะจาก Chicago Data Portal
 - ใช้ dbt Incremental Model โดยกำหนดจุดตัดข้อมูล (Watermark) จากคอลัมน์ Updated On

```
sql
{% if is_incremental() %}
  WHERE updated_on > (SELECT MAX(source_updated_at) FROM {{ this }})
{% endif %}
```

- ใช้กลยุทธ์ **Delete-and-Insert** ตามรหัสคดี (case_number) เพื่ออัปเดตสถานะคดี (เช่น ผลการจับกุม arrest_flag) ได้อย่างแม่นยำ และรักษาคุณสมบัติ **Idempotency** (รันซ้ำแล้วข้อมูลไม่เบิ้ล)


3.5.3 การออกแบบเวิร์กโฟลว์อัตโนมัติบน Apache Airflow (DAG Design)

เวิร์กโฟลว์การทำงานประจำวันถูกตั้งเวลาให้อัตโนมัติ (Daily Schedule) ผ่าน Airflow DAG ดังแผนภาพลำดับงาน



3.6 การออกแบบการควบคุมคุณภาพข้อมูล

เพื่อป้องกันปัญหา "Pipeline PASS, Business FAIL" ระบบได้นำกรอบทฤษฎีคุณภาพข้อมูล 6 มิติ (จาก บทที่ 2.5) มาแปลงเป็นกฎการตรวจสอบอัตโนมัติผ่าน **dbt Tests** และระบบกักกันข้อมูล (Quarantine Gate)



3.6.1 กฎการตรวจสอบคุณภาพข้อมูล (Data Quality Rules)

1. Uniqueness & Completeness (ความไม่ซ้ำซ้อนและความครบถ้วน):

- คีย์หลัก incident_key และ case_number ต้องไม่ซ้ำกัน (unique)
- คอลัมน์สำคัญทางธุรกิจ เช่น Date, Primary Type, IUCR, Beat, District ต้องไม่มีค่าว่าง (not_null)

2. Validity (ความถูกต้องตามกฎเกณฑ์และขอบเขต):

- วันเกิดเหตุ: ต้องไม่ใช้วันที่ในอนาคต ($date \leq CURRENT_DATE$)
- พิกัดภูมิศาสตร์ (Geographic Bounding Box): พิกัดต้องตกอยู่ภายในขอบเขตนครชิคาโกจริง คือ ละติจูด $41.64 \leq \text{Latitude} \leq 42.03$ และลองจิจูด $-87.94 \leq \text{Longitude} \leq -87.52$

3. Consistency (ความสอดคล้องตามกฎอ้างอิง):

- Foreign Keys ทุกตัวใน Fact Table ต้องสามารถเชื่อมโยง (Join) ไปยัง Surrogate Key ใน Dimension Tables ได้ครบถ้วน (relationships test)
- รหัส IUCR ต้องสัมพันธ์สอดคล้องกับ primary_type ตามตารางมาตรฐาน

3.6.2 การออกแบบตารางกักกันข้อมูล (Quarantine Table)

แถวข้อมูลดิบที่มีข้อผิดพลาดระดับวิกฤต (เช่น พิกัดหลุดโลก หรือข้อมูลสำคัญหายไปจนประมวลผลไม่ได้) จะถูกคัดแยกไปบันทึกไว้ในตาราง quarantine_crime_records พร้อมระบุเหตุผลความผิดปกติ (reject_reason) โดยไม่ปล่อยให้ข้อมูลชำรุดหลุดเข้าไปใน core_dw ช่วยรักษาความน่าเชื่อถือของรายงานและโมเดลพยากรณ์ความเสี่ยง

3.7 การออกแบบมาร์ตข้อมูลและระบบสารสนเทศเชิงภาพ

Presentation Layer บน **Metabase** ถูกออกแบบเพื่อตอบสนองการตัดสินใจของผู้ใช้งาน โดยดึงข้อมูลผ่านตารางสรุปผลลัพธ์ (Summary Tables) ในสกีมา data_marts เพื่อลดเวลาการคิวรีเฉลี่ยไม่เกิน 1–3 วินาที

3.7.1 การออกแบบตารางสรุปผลลัพธ์ (Summary Tables / Materialized Views)

1. mart_daily_beat_crime_summary (สรุปสถิติประจำวันระดับเขตตรวจ):

- **Grain:** 1 แถว ต่อ 1 วัน ต่อ 1 เขตตรวจ (Beat) ต่อ 1 หมวดหมู่คดีหลัก
- **Attributes:** date_key, beat_code, district_name, primary_type, is_weekend
- **Metrics:** total_incidents, total_arrests, total_domestic, และ arrest_rate_pct (คำนวณจาก $\frac{\sum \text{arrests}}{\sum \text{incidents}} \times 100$)

2. mart_spatial_heatmap (ชุดข้อมูลความหนาแน่นเชิงพื้นที่):

- รวบรวมพิกัด latitude, longitude, community_name, hour_24, shift_name, และน้ำหนักความรุนแรงของคดี เพื่อใช้สำหรับการเรนเดอร์แผนที่ความร้อน (Heatmap) ได้อย่างรวดเร็ว

3.7.2 การออกแบบโครงร่างหน้าจอแดชบอร์ด (Dashboard Wireframes)

ระบบแสดงผลบน Metabase ถูกออกแบบแยกตามมุมมองของผู้ใช้งาน 2 ระดับ:

1. แดชบอร์ดสำหรับผู้บริหารระดับสูง (Executive Decision Dashboard)

- **บัตรสรุปตัวชี้วัดหลัก (KPI Cards):** ยอดคดีรวมสะสมปีปัจจุบัน, อัตราความสำเร็จในการจับกุมภาพรวม (Arrest Rate %), สัดส่วนคดีความรุนแรงในครอบครัว, และอัตราการเปลี่ยนแปลงเทียบกับปีก่อนหน้า (YoY Growth)
- **กราฟแนวโน้มตามช่วงเวลา (Trend Chart):** กราฟเส้นแสดงสถิติคดีรายเดือนย้อนหลัง เพื่อวิเคราะห์ทิศทางและฤดูกาลของการเกิดเหตุ (Seasonality)
- **แผนภูมิจำแนกประเภทคดี (Crime Breakdown):** กราฟแท่งแสดงอัตราการจับกุมแยกตามประเภทคดี เพื่อชี้เป้าว่าคดีกลุ่มใดที่ยังมีผลงานการจับกุมต่ำ

2. แดชบอร์ดเชิงปฏิบัติการสำหรับสายตรวจ (Tactical Patrol Dashboard)

- **แผนที่ความร้อน (Interactive Crime Heatmap):** แสดงจุดเสี่ยงการกระทำความผิดของอาชญากรรม (Hotspots) ที่วนครชิดาโก โดยใช้ระดับความเข้มของสีแดงเพื่อระบุบริเวณวิกฤต
- **ตัวกรองเชิงพื้นที่และเวลา (Filters & Slicers):** ตัวกรองเลือกดูตาม **กะสายตรวจ** (Morning/Evening/Night Shift), วันในสัปดาห์, และสถานีตำรวจ (District)
- **ฟังก์ชันการเจาะลึกข้อมูล (Interactive Drill-down):** เมื่อเจ้าหน้าที่คลิกที่พื้นที่เสี่ยงบนแผนที่ ระบบจะ Drill-down แสดงรายละเอียดประเภทคดีย่อยและลักษณะสถานที่เกิดเหตุ (เช่น ตรอกซอย หรือทางเท้า) เพื่อให้หัวหน้าสายตรวจสั่งการนำรถสายตรวจไปประจำจุดได้อย่างแม่นยำ